

설명가능한 인공지능 활용 서울시 지하철 혼잡도 예측과 정책적 의사결정 지원을 위한 비즈니스 애널리틱스

Business Analytics to Predict Seoul Subway Congestion and Policy Decision-making using Explainable AI

박재흥 · 김경원*

국립대학법인 인천대학교 글로벌경영대학 무역학부

요약

2022년 기준 하루 평균 대중교통 이용 건수 약 1,025만 건 중에서 약 50.3%를 차지할 정도로 서울시민 중 절반 이상이 매일 지하철을 이용한다. 본 연구는 시민들이 승하차하는 과정에서 느낄 수 있는 혼잡도를 실시간으로 빠르고 정확하게 예측 및 설명함으로써 빅데이터 기반 실제 비즈니스의 활용도를 높이는 비즈니스 애널리틱스 방법론을 제시하는 것을 목적으로 한다. 6개 공공데이터베이스를 융합하여 대표적인 머신러닝 및 딥러닝 알고리즘으로 혼잡도를 예측하였고, 설명 가능한 인공지능인 SHAP 알고리즘으로 예측된 혼잡도의 근거를 실시간 효과적으로 제시하였다. Random Forest 알고리즘으로 95% 이상의 미래 혼잡도 예측 성능을 달성하였다. 혼잡도를 낮추기 위해 환승노선을 늘리는 사업이 확충되거나 비섬식형태의 승강장 플랫폼을 확충하는 것이 방법일 수 있다. 또한, 출근이 집중되는 월요일과 화요일에 혼잡도가 높아지기 때문에 근무 유연화를 통해 혼잡도의 개선이 가능할 것으로 생각된다.

■ 중심어 : 머신러닝과 딥러닝, 비즈니스 애널리틱스, 설명 가능한 예측, 지하철 혼잡도

Abstract

More than half of Seoul's residents use the subway every day, accounting for about 50.3% of the approximately 10.25 million average daily public transport trips as of 2022. This study aims to propose a business analytics methodology that improves the usability of big data-based real businesses by quickly and accurately predicting and explaining the congestion level that citizens may feel while getting on and off the subway. Six public databases are merged to predict the congestion level with representative machine learning and deep learning algorithms, and the SHAP algorithm, an explainable artificial intelligence, effectively presents the evidence of the predicted level. The Random Forest algorithm achieved a prediction performance of over 95% for future congestion. To reduce congestion, it may be possible to expand the number of transit routes or expand non-island platforms. In addition, since congestion is higher on Mondays and Tuesdays when commuting is concentrated, it is possible to improve congestion through work flexibility.

■ Keyword : Business Analytics, Explainable Prediction, Machine and Deep Learning, Subway Congestion

I. 서론

대한민국의 수도인 서울의 지하철은 약 600개의 역사에서 매일 약 800만 명이 이용할 만큼 대표적인 교통수단이다. 그리고 2022년 기준 하루 평균 대중교통 이용 건수는 약 1,025만 건인데, 그중에서 약 50.3%를 차지할 정도로 서울시민 중 절반 이상이 매일 지하철을 이용한다[1]. 또한, 업무 중심 또는 주거 중심 지역들이 많아 인구 밀집도가 높고 출퇴근 시간이나 사회적 정치적 이슈나 이벤트로 인해 특정 시간의 지하철 혼잡도가 증가하여 심각한 문제로 나타나고 있다. 실제 지하철 혼잡에 따라서 지하철 내 혼잡비용 2,317억 원과 열차 지연으로 인한 혼잡비용 4,960억 원이 발생하고 있다[2]. 향후 수도권 인근 신도시의 개발이나 다양한 형태의 교통수단이 개발될 예정이지만 혼잡도 증가가 해소될 수 있을지 예상하기 어렵고 모든 시간대의 혼잡도를 줄이기는 용이하지 않을 것으로 판단된다. 또한, 최근 전 세계적으로 확산하였던 코로나바이러스 역시 사람들이 밀집되는 폐쇄적 대중교통에서 강한 전염성을 보여 지하철 이용이 많이 감소하였기 때문에, 의학적으로나 서비스적으로 혼잡도 이슈는 다양한 방향으로 확산하기 쉽다.

이러한 사회적 이슈들을 개선하기 위해서는 다수가 이용하는 대표적 교통수단인 지하철의 혼잡도를 사전에 예측하는 것은 서비스의 효율성과 그리고 시민들의 편의성과 안정성 측면에서 중요한 의의가 있다[3]. 혼잡도를 높은 정확성으로 예측할 수 있다면 사전에 지하철 이용 패턴 또는 승객 흐름을 예측할 수 있음을 의미하며, 결과적으로 운행 빈도, 열차 편성, 인력 배치 등 운영 전략을 효과적으로 수립할 수 있다. 그리고 도시 계획이나 지속 가능한 교통 정책 기반 인프라 시스템을 구축하는데, 중요 참고자료가 될 수 있다. 또한, 높은 혼잡도로 승객들의 이동이 제한 및 응급 상황 대응이 어려워지

기 때문에[4] 사전에 예측된 혼잡도를 낮추기 위한 노력은 승객 안전성과 향상과 서비스 수익률과 직결될 수 있다.

교통상태의 혼잡을 완화하는 연구는 지속적으로 해결하려는 난제이다. 교통 시설이나 수단, 그리고 이용대상에 따라서 관련된 이론이나 방법론들이 다양하게 개발되고 있다. 이호 외(2015)은 승강장 혼잡도를 승강장 면적 대비 승차대기인원으로 정의하였다. 이 때 승차대기인원은 열차 탑승을 위해 대기하는 인원으로서 열차 출발정보와 승강장 누적진입인원을 활용하였다[5]. 이상준 외(2021)은 승강장 내 승객수와 승객 점유면적의 비율을 사용하여 혼잡도를 정의하였다. 승강장 내 승객이 실제 이용하는 대기 면적 개념을 제안하였으며, 승차승객 대기면적계수를 추정하였다. 승차승객 대기면적계수의 경우, 상대식 승강장은 0.291, 섬식 승강장은 0.270을 적용하여 혼잡도를 산정하였다[6]. 이상준 외(2020)은 1분 단위 승객 통행량과 승강장 통행량을 산출하고 승강장별 실용대기면적을 나누어 승강장 동적 혼잡도를 추정하였다[7].

관련 연구들을 종합하면, 지하철 혼잡도는 크게 세 가지로 구분될 수 있다. 첫 번째, 승강장 내에서 지하철을 승하차 하기 위해 대기할 때의 혼잡도이다. 둘째는 지하철에 탑승한 후 객차 내에서 승객들이 겪는 혼잡도이다. 공공데이터 포털의 “서울교통공사_지하철혼잡도정보” 데이터베이스가 수집하는 혼잡도는 정원 대비 승차인원으로 정의하고 승차인과 좌석수가 일치할 경우 혼잡도 34%로 산정한다. 세번째는 앞서 설명한 2가지의 혼잡도를 모두 혼합한 것이다. 지하철 전체 객차에 승객이 대기할 때의 혼잡도와 승하차가 이루어지는 일련의 과정에서 느끼는 객차 내 혼잡도를 모두 포함하여 승강장 내에서 겪는 승객들의 모든 혼잡도이다. 단순히 객차 안으로 한정할 경우 객차의 공간이 모두 점유가 되었다고 하더라도 객차 외부에서 대기하는 승

객들의 피로도를 반영하지 못할 수 있다. 반면 객차 외부로만 한정할 경우 사회적 이슈로 객차가 혼잡하지 않고 외부 승강장 내 혼잡이 발생하는 이슈를 반영하지 못한다.

〈표 1〉 지하철 혼잡도 예측과 교통분야의 인공지능과 XAI를 활용한 선행연구 분석 방향과 성능 요약

| 연구목적 | 선행연구 | 데이터 소스 | 데이터 기간 | 종속변수 | 분석내용 및 방법론 | 성능 |
|----------------|--------------------|---|---|-------------------|---|------------------------------|
| 정량적 지하철 혼잡도 예측 | 김근원 외 (2015) [8] | 서울시열린데이터 광장, 서울시통계 (3개 DB 활용) | 2013년 | 시간대별 객차 내 정원대비 인원 | 1~4호선 대상 상관관계 네트워크 1개 | 시각화 분석 |
| | Kim (2016) [9] | 국가통계포털, SNS 크롤링 (3개 DB 활용) | 2013~2014년 | 시간대별 객차 내 정원대비 인원 | 1호선 대상 다중회귀분석 1개 | 다중회귀분석 기준 75~84% |
| | Lee 외 (2019) [10] | 기상청자료, 교통카드자료 (DB 수 미기재) | 2011~2015년 | 연도별 승객통행량 | 대중교통 대상 분위회귀분석 1개 | 변수별 통계수치 분석 |
| | Shin 외 (2019) [11] | 교통카드자료 (1개 DB 활용) | 2016년 10월 17일 | 시간대별 면적 대비 승강장통행량 | 1~9호선 대상 규칙기반 알고리즘 1개 | 변수별 통계수치 분석 |
| | Liu 외 (2019) [12] | Nanjing Metro System (1개 DB 활용) | 2016년 3월 18일~4월 30일, 2016년 8월 1일~11월 9일 | 승객 경로 | 난징 1개역 대상 ARIMA, 딥러닝 등 10개 | 딥러닝 기준 RMSE 8.19 |
| | 권효승 외 (2020) [13] | 서울시 빅데이터 캠퍼스 (3개 DB 활용) | 2019년 10월~2020년 7월 | 시간대 및 최단경로별 승하차인원 | 1~9호선 대상 GRU 1개 | GRU 기준 Loss 0.0431 |
| | Lee 외 (2020) [7] | 교통카드자료 (1개 DB 활용) | 2016년 10월 17일 | 시간대별 면적 대비 승강장통행량 | 모든노선 대상 규칙기반 알고리즘 1개 | 변수별 통계수치 분석 |
| | Lee 외 (2021) [6] | 교통카드자료 (1개 DB 활용) | 2019년 05월 08일 | 승객점유면적 대비 승차대기인원 | 통행량 상위 30개역 대상 규칙기반 알고리즘 1개 | 변수별 통계수치 분석 |
| | Jang 외 (2023) [14] | 공공데이터포털 (4개 DB 활용) | 2019, 2022년 | 시간대별 객차 내 정원대비 인원 | 2호선 대상 Logistic Regression, Decision Tree, Random Forest 3개 | Random Forest 기준 83~99% |
| | Park 외 (2023) [15] | 공공데이터포털 (1개 DB 활용) | 미기재 | 시간대별 객차 내 정원대비 인원 | 3,5,6호선 대상 그래프 기반 딥러닝 1개 | 그래프 딥러닝 기준 34~97% |
| | Hu (2023) [16] | Subway Card Swipe Data (1개 DB 활용) | 2019년 1월 1일~20일 | 승객 유입과 유출 | 항저우 3개노선 대상 LSTM 1개 | LSTM 기준 R ² 97.1% |
| | Kim 외 (2024) [17] | 공공데이터포털, 서울시열린데이터 광장, 기상자료개방포털 (DB수미기재) | 2021~2023년 | 시간대별 객차 승하차인원 | 1~8호선 대상 MLP 1개 | MLP 기준 84% |

| 연구목적 | 선행연구 | 데이터 소스 | 데이터 기간 | 종속변수 | 분석내용 및 방법론 | 성능 |
|---------------------------|----------------------------|---|---|-------------------------|--|--|
| | Tian 외 (2024) [18] | EZ-Link Card Data (1개 DB 활용) | 2016년 1월~3월 | 승객수요 | 싱가폴 7호선 대상 ARIMA, Random Forest, LSTM, 자체개발 4개 | 자체개발 기준 MSE 2433.20 |
| | Luo 외 (2025) [19] | 자체수집 (DB 수 불필요) | 2020년 1월~2021년 3월 | 시간대별 객차 내 정원대비 인원 | 부산 1호선 대상 RNN 및 그래프 기반 딥러닝 6개 | Conv-LSTM 기준 89.11% |
| 교통분야 AI기반 혼잡도 예측 | Li 외 (2018) [20] | METR-LA of Los Angeles Country, PEMS-BAY of California (2개 DB 활용) | 2012년 3월 1일~6월 30일, 2017년 1월 1일~5월 31일 | 교통 속도 | ARIMA, VAR, SVR, FNN, FC-LSTM, DCNN, DCRNN, DCRNN-SEQ, GCRNN 등 10개 | DCRNN 기준 89.5~97.1% |
| | Pei 외 (2023) [21] | IC Card Swipe Data (1개 DB 활용) | 2021년 3월~10월 | 버스 승객수 | SVR, XGBoost, Bi-LSTM, ATT-BiLSTM, WPD-BiLSTM, WPD-ATT-BiLSTM 6개 | WDP-ATT- BiLSTM 기준 91.453~97. 717% |
| 교통분야 XAI기반 설명 | Monje 외 (2022) [22] | IC Card Swipe Data (1개 DB 활용) | 2015년 1월~2017년 2월 | 버스 승객수 | XGBoost, Random Forest, SVM, DNN, LSTM 등 7개 | LSTM 기준 R^2 89% |
| | Lee (2023) [23] | 도시재생종합정보 체계, 한국교통연구원, 통계청 (DB 수 미기재) | 2019년 | 인구밀도와 접근성 | 3000여개 읍면동 대상 머신러닝 + XAI 7개 | XGBoost 기준 R^2 91.3% |
| | 홍석준 외 (2024) [24] | 도로와 차량 드론 촬영 데이터 | 2024년 1주일 | 차선변경여부 | 대전시 유성구 대상 LSTM, Transformer, 자체개발 + XAI 3개 | 자체개발 기준 94.73~95.4 6% |
| | Lee 외 (2024) [25] | SKT 이동통신자료 | 2024년 1주일 | 화물과 비화물 운전자 통행분류 | 딥러닝 + XAI 1개 | 딥러닝 기준 71~83% |
| | Aboulola (2024) [26] | Accident Data from New Zealand Crash Analysis System (2개 DB 활용) | 2016~2020년 | 사고 부상 심각도 | MLP, CNN, LSTM, ResNet, EfficientNetB4, InceptionV3, Xception, MobileNet 8개 | MobileNet 기준 F1-score 98.48% |

본 연구에서는 시민들이 객차 내부든 외부든 혼잡함을 느낄 수 있는 모든 경우를 반영하기 위해 면적 대비 승하차인원을 예측하는 것을 목적으로 한다. 최근엔 머신러닝이나 딥러닝과 같은 인공지능 알고리즘으로 활용하여 혼잡도를 예측하려는 연구가 증가하고 있다. 이정훈 외(2019)

는 통계 기반 분위 회귀모형을 사용해서 부산광역시 의 기온, 습도, 풍속 등과 같은 기상정보와 대중교통 통행량과 밀접한 관련이 있음을 확인하였다[10]. Jang 외(2023)는 로지스틱 회귀분석(Logistic Regression)을 포함하여 의사결정나무(Decision Tree)와 랜덤 포레스트(Random Forest)

알고리즘을 사용하여 혼잡도를 예측하였고 정확성 기준 80% 이상의 성능을 달성하였다[14]. 해당 연구는 500m 이내 버스정류장 수, 역세권 건물 수 등 혼잡도 예측에 있어 새로운 지표를 사용했다는 점에서 의의가 있다. 김규진 외(2024)는 다층퍼셉트론 알고리즘을 사용하였지만, 공공데이터포털, 기상자료개방 포털, 열린 데이터 광장 등의 공공빅데이터를 활용하여 혼잡도를 예측하였다. 시간대별 특성과 기상 조건을 고려하여 지하철역 혼잡도를 예측한 점에서 의의가 있다[17]. 또한 지하철뿐만 아니라 버스나 교통 상황들을 예측하기 위해 도메인 특성에 맞는 딥러닝 알고리즘들을 개발하여 높은 성능을 달성한 연구들도 많아지고 있다[20-21]. 그 외에 관련 선행연구는 <표 1>의 연구목적 별로 상세하게 확인할 수 있다. 전반적으로 머신러닝과 딥러닝 알고리즘을 활용한 혼잡도 예측 연구가 성능이 증가되고 있음을 알 수 있다.

인공지능의 대표적 알고리즘인 머신러닝과 딥러닝은 높은 성능의 예측값을 제공하지만, 예측의 근거를 사람이 직관적으로 이해하기 어렵다는 한계가 있다. 특히 머신러닝과 딥러닝으로 진화하면서 “블랙박스(Black Box)” 모델로 불릴 정도로 내부 의사결정 과정이 불투명해, 사용자가 모델의 결정 이유를 해석하거나 검증하기 어렵다. 이러한 한계를 극복하고자 최근 설명 가능한 인공지능(Explainable AI, XAI)에 대한 관심이 높아지고 있다. XAI는 머신러닝, 딥러닝 등 복잡한 인공지능 알고리즘의 결과를 사람이 이해할 수 있는 형태로 설명하는 기술이다[27]. 단순히 “무엇을 예측했는가”를 넘어 “왜 그렇게 예측했는가”를 설명할 수 있게 하며, 모델 개발자 뿐만 아니라 최종 사용자, 정책 입안자, 서비스 관리자에게 중요한 정보를 제공한다. 이를 통해 사용자는 모델이 어떤 특성과 패턴을 기반으로 결정을 내렸는지 알 수 있으며 모델의 신뢰성(Trustworthiness)과 투명성(Transparency)을

높이는데 기여한다[28]. 지하철 혼잡도와 관련 되서는 아직까지 XAI를 활용한 연구들이 전무하지만, 다른 교통 분야에서는 인공지능 기반의 높은 성능 뿐만 아니라 해석까지 포함하고 있는 연구들이 늘어나고 있다. 특히 버스의 승객수를 예측하거나[22], 인구밀도[23]에 활용될 뿐만 아니라 교통상황과 사고를 상세하게 이해하기 위한 노력들이 증가하고 있다[24-26].

하지만 XAI를 활용하기 위해선 분석 모델링 이후 별도의 추가 계산이 필요하고 방법론에 따라서는 전체(Global) 설명보다는 부분적인 설명에 그치며 설명 결과가 비전문가에게는 다소 어려울 수 있다. 또한 모든 데이터와 모델에 완벽히 적용되지는 않으며, 복잡한 상호작용에 대한 설명과 실무 적용에는 여전히 기술적 도전이 요구되는 상황이다. 그럼에도 불구하고 이러한 연구들이 확산되고 여러 연구자들에게 이해도를 높일 수 있는 연구들이 많이 필요하다. 대표적인 XAI 기법에는 반사실적 설명(Counterfactual Explanations), 변수 중요도(Feature Importance), LIME (Local Interpretable Model-agnostic Explanations), SHAP (Shapley Additive Explanation) 등이 있다. 본 연구에서는 이러한 방법들 중 가장 기술적으로 완성도가 높은 SHAP (Shapley Additive explanation) 방법을 이용하여 고성능의 지하철 혼잡도 예측의 근거를 확인하고 변수들의 기여도를 분석한다. 게임 이론 기반의 셰플리 값(Shapley Value)을 활용해 각 변수의 기여도를 계산하므로 직관적이고 일관된 설명을 제공한다. 지하철 혼잡도 예측을 위해 기존에는 정성적인 접근 또는 제한된 인공지능 알고리즘을 활용하였지만, 본 연구는 대표적인 머신러닝과 딥러닝을 모두 활용하는 예측 방법론을 제공하는 동시에 설명가능한 인공지능을 통해 지하철 혼잡도 대응을 위한 접근을 추가함으로써 기존 문헌들을 확장하였다.

이후의 내용은 데이터를 병합하고 전처리하는 과정, 혼잡도 예측을 위해 사용된 머신러닝

과 딥러닝 알고리즘의 소개, 그리고 연구결과와 결론을 제시하며 마무리한다.

II. 연구방법

2.1 데이터 수집 및 병합

한국은 정보화 시대의 도래와 행정의 투명성 그리고 사회적 활용 효율성을 높이려는 노력으로 공공데이터를 수집하기 시작하였다. 이를 통해 국민의 정보 접근성이 높아졌으며 데이터 기반 정책을 수립하고 민간에서도 창의적인 활용을 할 수 있게 되었다. 본 연구에서는 지하철과 관련된 총 6개의 공공데이터베이스를 융합하여 지하철 혼잡도의 예측 성능을 개선하였다. <표 2>에 융합한 공공데이터베이스의 이름부터 기간, 단위, 추출변수, 그리고 종속변수 활용에 대한 상세 설명을 제시하였다. 데이터베이스의 수집 데이터의 기간은 2015년부터 2024년까지 다양하지만, 공통으로 추출될 수 있는 기간인 2021년부터 2023년까지 추출하였고, 데이터의 단위도 일 단위로 통일하여 통합하였다.

본 연구에서 서울교통공사에서 제공하는 “서울교통공사_1_8호선 역별 일별 시간대별 승객 유형별 승하차인원” 분기별 데이터베이스 3년치를 수집하여 기준데이터로 사용하였다. 해당 데이터는 날짜, 호선, 역번호, 역명, 승차여부, 하차여부, 승객유형에 따른 시간대별 승하차인원으로 구성되어 있다. 분기별로 변수명이 상이한 경우 동일하게 변경하였고, 특정 분기 데이터에서 24시간대 이후 변수가 존재하지만 약 46만개의 결측치로 구성되어 있어 제거하였다. 여기에서 승차인원수, 하차인원수 변수를 생성하고 동일 시간대의 승차 및 하차인원수를 합/차를 계산하여 승하차인원합/승하차인원차 변수를 추출하였다. 그리고 승객유형 정보에서 우대권을 사용한 승하차 인원과 청소년 승하차 인원을

<표 2> 설명가능한 지하철 혼잡도 예측을 위해 융합한 공공데이터베이스 정보

| 데이터베이스 (DB)명 | 기간 | 단위 | 추출변수 | 종속변수 활용 |
|-------------------------------------|-----------------|----|--|-------------------------------|
| 한국철도연구원_특일 정보 | 전체 | 일 | 연도, 월, 일, 요일, 공휴일, 대체공휴일 | - |
| 서울교통공사_1_8호선 역별 일별 시간대별 승객유형별 승하차인원 | 2015.01-2024.07 | 일 | 일별 승하차인원수, 우대권인원수, 청소년인원수 | 승강장 혼잡도 |
| 서울교통공사_지하철혼잡도 정보 | 2019-2024 | 분기 | 분기별 05시~23시 상하선 혼잡도(정원대비 승차인원) | - |
| 서울교통공사_월별 환승유입 인원 | 2019-2023 | 연 | 월별 환승유입인원수 | - |
| 서울교통공사_역사운영 현황 | 2024.06.30.기준 | 연 | 역사운영현황 (호선, 역명, 면적, 홍수, 승강장유형, 출입구수, 환승노선) | 승강장 혼잡도 |
| 서울교통공사_수송 순위 | 2019-2023 | 연 | 연도별 수송인원수 | 상위 10개역 필터링 및 종속변수 결측치 존재역 제외 |

을 추출하여 변수로 반영하였다. 다음으로 서울교통공사가 제공하는 “서울교통공사_지하철혼잡도정보” 데이터베이스는 30분 단위로 측정 후 연도별로 제공하는데, 일부 시간대에서 36~1133개 정도의 결측치가 확인되었다. 전체 샘플에 비해서는 미비하기에 해당 결측치는 제거하였고, 날짜, 호선, 역명, 상행여부, 하행여부에


따른 시간대별 혼잡도 지표로 구성되어 있다. 여기에서 시간대별 상선 혼잡도와 하선 혼잡도를 추출하여 변수로 구성하였다. 그런 다음 “날짜”를 공통 키(Key) 값으로 사용하여 기준데이터에 병합(Left Join)하였다. 다음으로 “서울교통공사_월별 환승유입인원” 데이터베이스는 연도별로 제공하는데, 2021년도의 데이터에서 최대 4개의 결측치를 발견하였고 나머지 연도에서는 결측치가 존재하지 않았다. 마찬가지로 결측치의 개수가 매우 미비하여 제거하였다. 그리고 2021년도는 월별 환승유입인원이 열로 반영되어 있어서 행으로 구성되어 있는 2022년과 2023년도와 구조를 맞추기 위해 행으로 변환후 병합(Concat)하였다. 최종적으로 날짜, 호선, 역명, 환승유입인원수로 구성되어 있고 “날짜”를 공통 키(Key)로 활용하여 앞선 데이터베이스들과 병합(Left Join)하였다. 그리고 2024년 6월 30일 기준 “서울교통공사_역사운영 현황” 데이터베이스에서 호선, 역명, 면적, 층수, 승강장유형, 출입구, 환승노선을 알 수 있다. 여기에서 결측치는 166개였는데 이는 환승노선이 없는 역을 의미하기에 0으로 처리하였다. 따라서 날짜별 역별 면적, 층수, 섬식여부와 같은 승강장유형, 출입구, 환승노선 갯수를 추출할 수 있었으며 “날짜”를 공통 키(Key) 값으로 사용하여 앞선 데이터베이스들에 병합(Left Join)하였다. 그리고 기존에 추출한 승하차인원합 변수에서 면적을 나누어서 종속변수로 생성할 수 있었다. 마지막으로 모든 데이터베이스의 공통 키값으로 사용된 “날짜”를 활용하여 년도, 월, 일, 요일, 주 변수를 만들었고, 파이썬 holidayskr 라이브러리를 통해 공휴일 변수를 생성하여 시계열 정보들을 지하철 혼잡도 예측에 활용할 수 있었다.

생성된 공공빅데이터 기반 융합 데이터베이스에서 종속변수를 예측하기 위해 나머지 23개의 독립변수들을 사용하여 모델링할 때 알고리즘이 이해할 수 있는 형태로 전처리 후 반영해

야 한다. 전처리 과정에서 불필요한 변수들을 삭제하기도 하고 문자로 된 응답 값은 별도의 변수나 숫자로 변환하며 최종적으로 정리된 숫자들은 응답 값의 범위를 맞추기 위해 특정 범위로 스케일을 맞춘다. 마지막으로 평균적으로 역마다 약 5.49만개 정도의 샘플들을 랜덤하게 8:2의 비율로 구분하여 훈련 (Training) 세트와 테스트 (Test) 세트로 분리하였다. 연구에 활용한 데이터는 시계열이지만 실제 혼잡도를 예측하는 시간 단위는 월별이나 주별이 아닌 “시간”이다. 그리고 지하철의 특성상 바로 직전 시간의 정보가 현재와 미래 시간의 혼잡도에 영향을 주기보다 출근시간대, 퇴근시간대, 휴일 등과 같이 특정 상황에 따라 혼잡도가 더 영향을 줄 가능성이 높다. 또한 각 시간별 과거 3년치의 패턴이 반영되는 만큼 유사한 시간이나 시간대별 샘플들이 풍부하다. 따라서 바로 직전 시점들의 영향을 고려한 시계열 알고리즘을 직접적으로 사용하기 보다 시계열의 패턴을 파생 변수로 반영하는 것이 적합할 것으로 생각된다. 그러므로 시간적인 순서로 데이터를 분리하지 않고 랜덤하게 데이터를 분리하였고, 시간 정보를 반영하기 위해 후술될 전처리 과정에서 연도, 월, 요일, 주, 공휴일 여부 등의 시간패턴을 반영한다. 훈련 세트는 모델링을 위한 학습에 사용되고 모델의 하이퍼파라미터를 결정하기 위해 평균 제곱 오차 (Mean Squared Error, MSE)가 최소가 되는 방향으로 설정하였다. 그리고 테스트 세트는 학습되지 않은 과거와 유사한 상황이 미래에도 발생할 수 있다는 가정하에 활용되는 데이터로 학습된 모델이 얼마나 지하철 혼잡도를 잘 예측하는지 검증하는 데 사용된다. 기본적으로 지하철 혼잡도가 어떤 원인으로 설명되더라도 그 해석이 과거와 그리고 이와 유사한 상황들에서 고객들이 이용할 지하철의 혼잡도를 실제로 잘 예측하는 모델에 대한 설명이어야 고객들이나 관련 의사결정자들에게도 정책적 활용 가치가 높을 것이다.

2.2 데이터 전처리 및 변수 추출

본 연구를 위해 각 데이터베이스에서 추출할 수 있는 변수들을 생성하였고 필요에 따라서는 여러 개의 데이터베이스 변수들을 결합하여 생성하였다. 총 수집된 데이터의 양은 약 55만개의 샘플과 총 24개의 혼잡도 관련 변수가 생성되었다. 그리고 혼잡도가 낮은 경우보다 혼잡도가 높은 경우를 집중적으로 예측이 필요하므로 결측치가 존재하지 않는 경우 중 수송인원수가 많은 상위 10개의 역을 예측 대상으로 선정하였다. 수집된 데이터의 지하철 노선은 1호선부터 8호선까지 중 2호선이 총 7개의 역으로 가장 많이 포함되어 있다. 본 연구의 종속변수인 승강장혼잡도는 “면적 대비 승하차인원”으로 정의된다. 승강장 혼잡도의 평균값은 59.97이며 최소 0.25부터 최대 502.32까지 분포되어 있다. 그리고 승강장 혼잡도를 제외한 나머지 23개의 변수가 독립변수로 사용되어 승강장혼잡도를 예측하는 주요 요인들로 활용된다. 추출된 변수들의 이해도를 높이기 위해서 <표 3>에 사용한 변수명과 예시, 그리고 설명을 제시하였다. 그리고 승강장혼잡도와 나머지 독립변수들과의 관계성을 확인하기 위해 상관관계 분석 시각화를 <그림 1>에 제시하였다.



<그림 1> 혼잡도 예측에 사용한 변수들의 상관관계

<표 3> 설명가능한 지하철 혼잡도 예측에 사용한 변수명, 예시 및 정의

| 특성 | 변수명 | 예시 | 정의 |
|----------|-----------|------------|----------------------------|
| 시간 정보 | 연도 | 2021.0 | 해당 열차가 운행된 연도 |
| | 월 | 12.00 | 해당 월(1~12) |
| | 요일 | 1.00 | 해당 날짜의 요일 여부 |
| | 주 | 52.00 | 해당 날짜가 포함된 연중 주차 |
| | 공휴일 | 1.00 | 공휴일 여부(0: 평일, 1: 공휴일) |
| 승객 이용 현황 | 일별 승하차인원수 | 1072328.00 | 해당 일자의 총 승하차 인원수 |
| | 우대권인원수 | 110.00 | 역별 시간대별 우대권 이용 승객 수 |
| | 청소년인원수 | 131.00 | 역별 시간대별 청소년 이용 승객 수 |
| | 상하선 혼잡도 | 33.75 | 해당 시간대 상행선 및 하행선 열차 혼잡도 지표 |
| | 환승유입 인원수 | 41.75 | 환승을 통해 유입된 승객 수 |
| | 수송인원수 | 1418813.00 | 월별 해당 역에서 수송된 전체 승객 수 |
| 역사 운영 현황 | 호선 | 8.00 | 지하철 노선 번호 |
| | 역명 | 서울역 | 해당 지하철 역 이름 |
| | 면적 | 10805.00 | 해당 역의 면적 |
| | 승강장 유형 | 1.00 | 승강장 유형(0: 상대식, 1: 섬식) |
| | 출입구 수 | 9.00 | 해당 역의 출입구 개수 |
| | 환승노선 | 3.00 | 해당 역에서 환승 가능한 노선 개수 |

2.3 머신러닝 및 딥러닝 모델링

본 연구에서는 Linear Regression, Random Forest, XGBoost, LightGBM, CatBoost 총 5개의 머신러닝 알고리즘과 2개의 대표적인 딥러닝 알고리즘인 MLP (Multi-Layer Perceptron), CNN (Convolutional Neural Network)을 사용하여 모델

링하였다. 머신러닝은 인공지능의 한 방법론으로 예측 오차를 줄이는 방향으로 설계되었다. 오차는 편향과 분산으로 분리될 수 있는데, 예측의 안정성에 초점을 두어 분산을 줄이기 위해 샘플링 기법을 활용하는 배깅(Bagging)과 성능에 초점을 두어 편향을 줄이기 위해 반복적인 모델링을 활용하는 부스팅(Boosting)으로 구분될 수 있다.

딥러닝도 인공지능의 한 방법론으로, 인간의 두뇌 구조에서 영감을 받아 개발되었다. 데이터의 복잡한 패턴들을 학습하기 위해 연속된 층(Layer)을 중첩하여 변수들의 모든 상호작용을 포함하여 의미 있는 규칙들을 학습해 내는 데 강점이 있다. 이러한 구조의 기본이 되는 알고리즘으로 다층 퍼셉트론이 있으며, 이미지나 시계열 등의 데이터도 학습해 낼 수 있도록 층의 구조나 흐름을 개선하여 합성곱 신경망과 순환 신경망 등으로 확장되었다. 특히 CNN은 이미지 분류 특화 알고리즘이지만 내부 구조가 결국 특징을 요약한 것이기 때문에 회귀 문제에도 활용할 수 있다. 특징을 요약하기 위해 합성곱, 풀링, 완전 연결층을 활용하여 인접한 특성값들의 관련성에 더욱 초점을 두어 학습한다. 따라서 다양한 변수들의 상호작용을 포함한 특징들이 학습될 것이고 마지막 출력은 지하철 혼잡도 값이 출력되며 회귀 문제를 해결한다. 알고리즘을 성능을 공평하게 비교하기 위해 가급적 같은 매개 변수값을 사용하였다 <표 4>.

2.4 설명가능한 인공지능: SHAP

머신러닝과 딥러닝은 발생 가능한 변수들의 모든 상호작용을 스스로 생성하여 학습하기 때문에 인간의 수준을 뛰어넘는 성능 달성을 가능하게 하였다. 하지만 왜 그러한 결과가 발생한 것인지 쉽게 확인하거나 설명하기는 어려운 블랙박스 알고리즘이다. 일부 머신러닝 알고리즘이 변수들의 중요도 (Feature Importance)를 출력하지만, 방향성이 없으

<표 4> 지하철 혼잡도 모델링에 사용한 알고리즘의 하이퍼파라미터

| Algorithm | Parameter | Value |
|-------------------|---|--------------------|
| Linear Regression | Intercept | True |
| | Max Iteration | 100 |
| | Random State | 0 |
| Random Forest | Samples | 100 |
| | Criterion | Gini |
| XGBoost | Minimum Spitting Samples | 2 |
| LightGBM | Random State | 0 |
| MLP | TensorFlowRandomSeed | 0 |
| | Number of Hidden Layers | 2 |
| | Unit Numbers for Hidden Layers (100, 100) | |
| | Activation for Hidden Layers | Relu |
| | Activation for Output Layers | Identity |
| | Loss | Mean Squared Error |
| | Optimizer | Adam |
| | Epochs | 500 |
| CNN | TensorFlow Random Seed | 0 |
| | Number of Convolution Layers | 1 |
| | Unit Numbers for Convolution Layers | 64 |
| | Number of Dense Layers | 2 |
| | Kernel Size | 2 |
| | Stride | 1 |
| | Padding | Vaild |
| | Unit Numbers for Dense Layers | 64 |
| | Activation for Hidden Layers | Relu |
| | Activation for Output Layer | Linear |
| | Loss | Mean Squared Error |

므로 해석에 주의를 기울여야 한다. 하지만 SHAP (SHapley Additive exPlanations)는 지역적 해석 가능한 모델 독립 설명 (Local Interpretable Model-agnostic Explanations, LIME)과 셰플리 값 (Shapley Value)을 연결한 이론으로, 이러한 블랙박스와 같은 알고리즘들의 한계를 보완하여 지하철 혼잡도

예측에 영향을 주는 변수들의 특징과 방향을 설명해준다. LIME은 주어진 데이터 값들을 변화시킬 때 모델 예측값의 변화와의 관련성을 가중치로 계산한다. 그리고 셰플리 값은 협력 게임 이론 (Coalitional Game Theory)을 기반으로 변수들의 기여도를 계산하는 지표다. 따라서 변수들이 가질 수 있는 모든 협력 조합의 경우들을 생성한 후 실제 값들이 입력되었을 때 변화된 예측값의 기여도 평균을 계산한다. 하지만 연산량이 매우 많을 수 있으므로 랜덤 샘플링 기법을 활용하여 계산의 효율성을 높인다. 이 2가지 이론이 결합한 SHAP를 사용하여 지하철 혼잡도에 기여하는 변수들의 정도와 방향성을 알 수 있고 블랙박스과 같은 인공지능 알고리즘을 설명 가능케 한다.

2.5 성능평가 지표

지하철 혼잡도를 예측하고 설명의 신뢰성을 높이기 위해 6개의 회귀 평가 지표를 사용하여 모델링의 성능을 확인한다. 이들은 RMSE (Root Mean Squared Error), MSPE (Mean Squared Percentage Error), MAE (Mean Absolute Error), MAPE (Mean Absolute Percentage Error), MedAE (Median Absolute Error), MedAPE (Median Absolute Percentage Error)이다. 모든 지표는 예측 성능이 좋을수록 낮은 수치들이 나오도록 실제값과 예측값의 차이로 구성되어 있다. 따라서 6개의 평가 지표 모두 낮은 수치가 나오는 경우 지하철 혼잡도를 잘 예측하는 모델이라 볼 수 있다.

III. 연구결과

3.1 예측 성능평가

지하철 혼잡도의 예측 성능을 검증하기 위해 머신러닝 및 딥러닝 알고리즘의 테스트 데이터에 대한 성능을 확인하는 것이 주 목적이다. 알고리즘에 데이터를 학습시켜 모델링을 한 후,

〈표 5〉 알고리즘별 수송인원수 상위 10개 역의 미래 예측성능 검증지표들 중 퍼센트 오차평균

| Dataset | Ranking | MSPE | MAPE | MedAPE |
|---------|-------------------|--------------|--------------|---------------|
| Train | Random Forest | 0.00% | 0.20% | 6.86% |
| | MLP | 0.16% | 1.45% | 78.52% |
| | CNN | 0.38% | 3.12% | 176.71% |
| | XGBoost | 2.53% | 8.94% | 607.59% |
| | LightGBM | 2.11% | 8.97% | 664.31% |
| | CatBoost | 3.81% | 11.47% | 883.12% |
| | Linear Regression | 71.76% | 43.36% | 3081.28% |
| Test | Random Forest | 5.01% | 5.32% | 17.34% |
| | MLP | 7.17% | 8.24% | 59.44% |
| | CNN | 7.13% | 8.37% | 74.27% |
| | XGBoost | 7.91% | 12.34% | 339.08% |
| | LightGBM | 8.22% | 12.37% | 345.00% |
| | CatBoost | 10.10% | 14.66% | 479.05% |
| | Linear Regression | 224.66% | 60.74% | 2879.37% |

과적합 여부를 동시에 확인하고자 훈련과 테스트 데이터에서의 예측 성능을 <표 5>에 제시하였다. 지면상 10개의 지하철 역 각각에 대한 예측 성능 대신 알고리즘별로 10개역 6개 검증지표 수치를 평균을 하였을 때, Random Forest 알고리즘이 학습데이터에선 MSPE와 MAPE 기준 각각 0.00%와 0.20%를 나타낼 정도로 매우 정확하게 예측을 하였고 테스트 데이터에선 5.01과 5.32%의 오류를 나타내며 1순위를 차지하였다. 차지할 만큼 10% 미만의 오차를 보이며 정확하게 지하철 혼잡도를 예측하는 것으로 나타났다. 2순위를 차지한 MLP도 학습데이터에선 MSPE와 MAPE가 각각 0.16%와 1.45%로 매우 낮은 오류를 나타내었고 테스트 데이터에선 7.17%와 8.24%를 나타낼 정도로 높은 정확도를 보였다. 또한 3순위의 CNN 알고리즘도 MLP와 유사한 수치를 보인다. 나머지 머신러닝 알고리즘도 성능이 매우 떨어지진 않는 편이다. 반면 전통적인 선형회귀분석 알고리즘은 훈련과 테스트 모두에서 최하위 순위를 차지했고 테스트의 MSPE가 224.66%인 만큼 매우 부정확한 예

측임을 알 수 있다. 그리고 모든 알고리즘의 테스트 예측 성능은 훈련데이터의 예측 성능을 뛰어넘지는 못하였고, 훈련데이터에만 유독 과적합 되는 상황은 아닌 것으로 판단된다.

추가적으로 정차역에 따라서 알고리즘의 순위가 달라지는지 여부를 확인하기 위해서, 각 역마다 모든 알고리즘의 검증지표 순위를 추정 한 후 10개역의 순위 평균치를 <표 6>에 제시하였다. RMSE와 MSPE의 경우 MLP 알고리즘이 10개역 평균 순위가 1.38로 가장 높게 나타난다. 즉, RMSE 지표에서는 대부분의 역에서 MLP 알고리즘의 지하철 혼잡도 예측 순위가 1등으로 나타남을 의미한다. 그런데 RMSE와 MSPE를 제외한 나머지 4개 검증지표에서는 랜덤 포레스트 알고리즘이 10개역 평균 순위가 1.08와 1.00으로 나타났다. 따라서 나머지 검증지표들에선 랜덤 포레스트 알고리즘이 거의 항상 1등을 차지했음을 의미한다. 따라서 6개의 검증지표를 기준으로 Random Forest와 MLP 알고리즘이 일반적으로 지하철 혼잡도를 예측하는데 활용도가 높을것으로 판단된다.

<표 6> 수송인원수 상위 10개 역의 미래 예측 성능 검증지표 순위 평균

| Algorithm | RMSE | MSPE | MAE | MAPE | MedAE | MedAPE |
|-------------------|-------------|-------------|-------------|-------------|-------------|-------------|
| Linear Regression | 7.00 | 7.00 | 7.00 | 7.00 | 7.00 | 7.00 |
| Random Forest | 1.92 | 1.92 | 1.00 | 1.08 | 1.00 | 1.00 |
| XGBoost | 4.54 | 4.54 | 4.46 | 4.46 | 4.46 | 4.46 |
| LightGBM | 4.52 | 4.54 | 4.69 | 4.62 | 4.52 | 4.62 |
| CatBoost | 5.92 | 5.92 | 5.85 | 5.92 | 6.00 | 5.92 |
| MLP | 1.38 | 1.38 | 2.54 | 1.92 | 2.31 | 2.08 |
| CNN | 2.69 | 2.69 | 2.46 | 3.00 | 2.69 | 2.92 |

3.2 지하철 혼잡도 예측의 설명력 분석

머신러닝 그리고 딥러닝과 같은 인공지능 알

고리즘은 복잡한 비선형 패턴과 변수들의 모든 상호작용 조합까지도 학습을 하여 모델을 만들기 때문에 예측에 기여하는 독립변수들의 기여도를 단순하게 파악하기 어렵다. SHAP를 사용하면 지하철 혼잡도의 높은 미래 예측 성능이 왜 그러한지 독립변수들의 상대적 기여도로 평가할 수 있다. 따라서 높은 예측 성능 뿐만 아니라 독립변수들이 어떠한 방향으로 기여해서 그러한 높은 미래 예측 성능을 달성하였는지 설명해주기 때문에, 실제 지하철 교통 비즈니스에 활용되기도 용이하고 신뢰성도 높아 의사결정에 용이하게 활용될 수 있다. 그리고 이러한 실시간 혼잡도처럼 누적된 혼잡도 예측과 설명력들을 모두 결합하여 일반화된 정책으로 활용할 수 있는 설명력을 시각적으로 표현하기 때문에 이해하기 쉽다.

SHAP 알고리즘은 개별 지하철 혼잡도에 대한 설명을 Decision Plot으로 제공해주며, 이를 누적하여 전체 지하철 혼잡도는 Summary Plot으로 표현해준다. Decision Plot은 X축은 해당 변수에 대한 혼잡도 예측에 미치는 정도인 SHAP 값을 표현하며, Y축은 변수의 중요도를 내림차순으로 표현한다. 따라서 표시된 선그래프는 제일 아래에 있는 변수의 예측 기여 SHAP 값을 위로 누적시키며 최종적인 혼잡도 예측을 표현한다. 실제로 위로 올라갈수록 이전 SHAP 값 대비 기울기가 커지듯 그만큼 혼잡도 예측에 영향이 크다고 판단할 수 있다. 그러므로 개별 혼잡도에서 어떤 변수들이 주요 결정 요인인지 파악하는데 용이하다. Summary Plot의 X축은 Decision Plot과 마찬가지로 해당 변수의 예측 기여 SHAP 값이다. Y축도 변수의 중요도를 내림차순으로 표현하지만 변수별로 샘플기여 SHAP 값을 누적하여 분포로 표현한다. 따라서 개별기여 값을 점으로 표현하고 색상을 통해 값의 변화에 대한 예측 기여 방향을 표현한다. 그리고 분포변화가 클수록 예측에 크게 기여하는 것이기 때문에 위로 갈수록 혼잡도 예측에 크게 기여한다. 그러므로 전체

예측에 대한 주요변수 우선순위와 해석으로 모델의 전반적인 이해와 의사결정에 활용될 수 있다. 좀 더 상세한 변수의 중요도와 방향성 그리고 해석과 활용에 대해 <표 7>에 정리하였다.

〈표 7〉 SHAP 알고리즘이 제공하는 Decision Plot과 Summary Plot의 해석방법과 설명 그리고 활용목적 요약

| 구분 | Decision Plot | Summary Plot |
|-------|--|--|
| 대상 | 개별 샘플 | 전체 데이터 |
| 해석 방법 | <p>> X축: 변수의 예측 기여 SHAP 값</p> <p>> Y축: 변수중요도 내림차순 기반 누적 기여 SHAP 값</p> <p>> 선그래프: 기울기 기반 해당변수 영향력</p> <p>(기울기 변화가 클수록 예측에 크게 기여하기에 위로 갈수록 중요)</p> | <p>> X축: 변수의 예측 기여 SHAP 값</p> <p>> Y축: 변수중요도 내림차순 기반 변수별 샘플기여 누적 SHAP 값</p> <p>> 분포선그래프: 변수값의 변화에 따른 예측기여 방향과 정도</p> <p>- 파란색: 변수의 낮은값에 대한 SHAP 값 분포</p> <p>- 빨간색: 변수의 높은값에 대한 SHAP 값 분포</p> <p>- 파란색->빨간색 분포변화: 예측에 대한 긍정 기여</p> <p>- 빨간색->파란색 분포변화: 예측에 대한 부정 기여</p> <p>(분포변화가 클수록 예측에 크게 기여하기에 위로 갈수록 중요변수)</p> |
| 설명 | <p>개별 예측의 결정 경로를 누적 SHAP 값으로 시각화</p> <p>(선=개별기여, 변수=결정경로 우선순위)</p> | <p>개별 예측의 변수별 기여 방향을 누적하여 SHAP 값 분포로 시각화</p> <p>(점=개별기여, 색=기여방향, 변수=전체결정 우선순위)</p> |
| 활용 목적 | <p>1) 개별 예측의 주요 변수 식별과 결정과정 추적</p> <p>2) 샘플결과간 비교를 통한 개별샘플 인사이트 확보</p> | <p>1) 전체 예측의 주요변수 식별과 영향방향 해석</p> <p>2) 모델의 전반적인 이해로 의사결정 지원</p> |

우선 실시간 지하철 혼잡도에 대한 설명력을 의사결정 플롯 (Decision Plot)으로 시각화하였다. 가장 높은 성능을 보이는 Random Forest 알고리즘을 기준으로, <그림 2>은 학습에 사용되지 않은 특정일을 임의로 선택하여 강남역 혼잡도를 예측하고 어떻게 측정된 것인지 실시간으로 변수들의 기여도를 내림차순으로 보여준다. <표 7>의 해석방법에 따르면 특정 샘플의 최종 혼잡도가 얼마나 예측이 되었는지 어떤 이유로 예측값이 나왔는지 결정경로를 선그래프로 표현하고 있으며, 선의 기울기에 따라 기여 방향을 확인할 수 있다. 실제 강남역의 혼잡도가 약 105점 정도로 높을 때 하차인원, 출입구, 수송인원수, 환승노선_개수, 청소년인원수 등은 혼잡도를 높이는 변수들이고 “승차인원, 섬식여부, 년도” 등은 혼잡도를 낮추는 변수들이다. 그 외 나머지 변수들은 혼잡도에 크게 기여하지 못한다. 하지만 강남역 혼잡도가 낮을 때 “승차인원, 하차인원, 수송인원수, 환승노선_개수, 출입구” 등은 오히려 혼잡도를 낮추는 변수로 작용하기도 한다. 그리고 “섬식여부”도 반대로 혼잡도를 높이는 데 기여하고 있다. 미래 특정일과 상황에 따라 변수들이 혼잡도를 높이거나 낮추는데 기여하는 정도나 방향은 얼마든지 달라질 수 있었다. 이러한 과정에서 실시간으로 높은 정확도의 혼잡도를 예측할 뿐만 아니라 어떻게 그러한 수치가 나오게 되는지 의사결정 근거로 활용하기에도 매우 용이하다.

특정일의 지하철 혼잡도에 대한 변수들의 기여를 통해 각 변수가 지하철 혼잡도에 일반화된 기여 방향을 보장하지 않는다. 그러한 이유로 특정 변수가 지하철 혼잡도에 어떠한 방향성을 가지는지 일반화하는 것은 다소 위험할 수 있다. 정책적 근거를 위해 일시적으로 사용할 수는 있겠지만 정책 입안자들 또는 시민들에게 이해될만한 정보로 실시간으로



(가) 혼잡도 높을 때



(나) 혼잡도 낮을 때

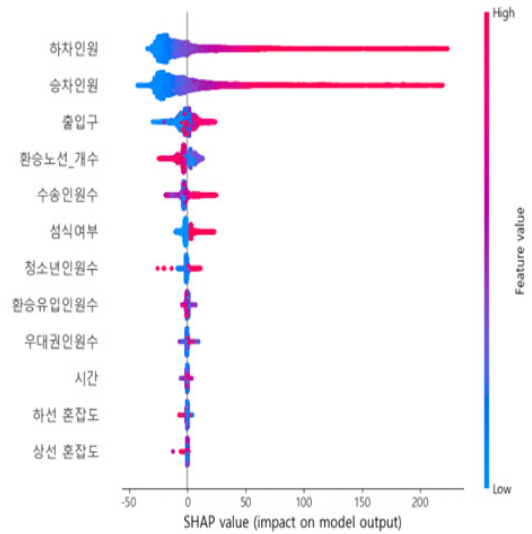
〈그림 2〉 학습에 사용되지 않은 특정일 대상 강남역의 혼잡도 예측과 변수기여 설명력 기반 의사결정

와닿기 어렵기 때문이다. 하지만 실시간 혼잡도의 예측 설명력을 확인할 수 있었으니 이를 누적하여 표현한다면 충분히 일반화된 인사이트로 재표현 할 수 있을 것이다. 단, 기여 방향을 공부정과 같은 이분법적인 해석은 매우 조심해야 함을 위의 실시간 예측 결과를 통해 다시 한번 강조한다. 따라서 본 연구에서는 매우 명확한 관계성이 나타나는 변수에 대해서만 조심스럽게 해석을 제안하면서 머신러닝과 딥러닝 기반의 설명 가능한 인공지능의 효과적인 비즈니스 애널리틱스를 안내하는 데 집중한다.

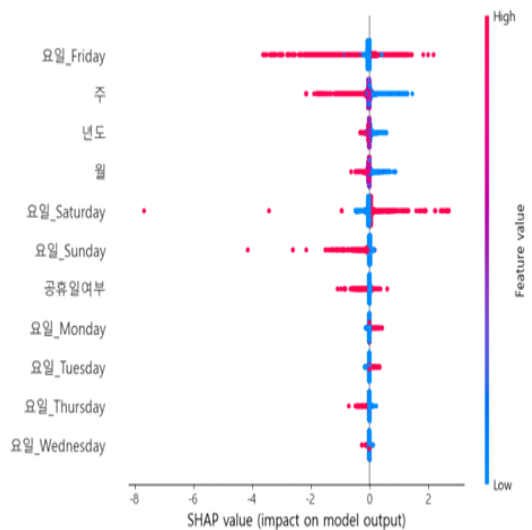
각 샘플마다의 지하철 혼잡도 예측 설명력을 누적한 요약 플롯(Summary Plot)을 통해 전체의 일반화된 설명력을 확인할 수 있다. 그리고 <표 7>의 해석방법에 따르면 각 변수들마다 지하철 혼잡도에 어떠한 우선순위와 방향으로 기여를 하고 있는지 분포 선그래프로 표현하고 있으며, 색상의 변화에 따라 기여 방향을 일반화 할 수 있다. <그림 3>는 Random Forest 알고리즘으로 학습에 사용되지 않은 모든 테스트 데이터의 지하철 혼잡도 예측을 위한 특성 영향을 시각화한 것이다. 우선 세로축은 왼쪽과 오른쪽으로 2개가 있다. (왼쪽)세로축은 종속 변수에 영향을 주는 변수 중요도를 내림차순으로 정렬한 것이기 때문에 높은 곳에 있는 변수들은 낮은 곳에 있는 변수들보다 지하철 혼잡도 예측에 더욱 많이 기여한다. 즉, “하차인원, 승차인원, 출입구, 환승노선_개수, 수송인원수” 등의 순서로 예측 성능의 변수 기여도가 분석되었다. 그리고 (오른쪽)세로축은 변수들의 값이 낮은 경우는 파란색 계열로 그리고 높은 경우는 빨간색 계열로 표시하여 변수들의 값의 변화를 표시하였다. 마지막으로 가로축에 바로 지하철 혼잡도의 예측값을 표시하여 변수의 값의 변화에 따라 낮은 혼잡도(음수)에서 높은 혼잡도(양수)로의 예측값 변화를 이해할 수 있다.

관련 설명은 <표 7>을 통해 상세히 요약되어 있다. 시점마다 변수의 수치는 다양할 수 있고 수치별 지하철 혼잡도 또는 특성 영향 방향도 다양할 수 있으므로, 각 변수의 값과 대응되는 예측값 위치를 모두 누적하여 표현하면 각 변수의 값의 변화에 따른 지하철 혼잡도 기여 방향이 시각화되는 것이다.

“하차인원과 승차인원”은 값이 작을 때(파란색 계열) 혼잡도가 낮게 예측되는 경향이 있고 값이 커지면(빨간색 계열) 혼잡도가 높게 예측되는 경향이 있다. 따라서 해당 변수의 값이 커지면 지하철 혼잡도가 높아진다고 해석할 수 있다. 반대로 “환승노선_개수”는 값이 커질수록 지하철 혼잡도를 낮춘다고 해석할 수 있다. 이를 정리하여 미래에 지하철 혼잡도를 높일 것으로 예측되는 가장 중요한 변수는 “하차 인원, 승차 인원, 출입구, 섬식 여부, 월요일, 화요일” 등이며, 혼잡도를 낮출 것으로 예측되는 변수는 “환승노선_개수, 환승유입인원수, 하선/상선 혼잡도, 주, 년도, 월, 일요일, 목요일, 수요일” 등으로 해석할 수 있다. 단순히 지하철 관련 변수들뿐만 아니라 시간 정보에 따른 혼잡도 기여도 확인할 수 있다. 단, 이러한 해석은 연구에 활용한 데이터의 수에 한정된 결과다. 향후 수집 샘플이 증가되며 다양한 혼잡도에 따른 변수 패턴들이 반영된다면 결과는 언제든지 달라질 수도 있다. 따라서 <그림 1>과 <그림 2>와 같이 혼잡도에 영향을 주는 변수들을 실시간 분석할 수 있는 비즈니스 애널리틱스의 필요성이 더욱 중요해 질 것이다. 또한 지하철 혼잡도에 대해 입력된 모든 변수들을 해석할 수 있는 장점을 살려, 단일 변수에 의존된 정책 제안보다는 복합적인 정책 제안에 활용하는 것을 추천한다.



(가) 우선순위 1-12



(나) 우선순위 13-23

<그림 3> 지하철 혼잡도 예측에 대한 변수들의 기여 설명력 기반 의사결정

IV. 결론

최근 전 세계적으로 확산하였던 코로나바이러스 역시 사람들이 밀집되는 폐쇄적 대중교통에서 강한 전염성을 보여 지하철 이용이 크게

감소하였기 때문에, 의학적으로나 서비스적으로 혼잡도 이슈는 다양한 방향으로 확산하기 쉽다. 사회적 이슈들을 개선하기 위해서는 다수가 이용하는 대표적 교통수단인 지하철의 혼잡도를 사전에 예측하는 것은 서비스의 효율성과 그리고 시민들의 편의성과 안정성 측면에서 중요한 의의가 있다. 한국의 대중교통들 중 지하철은 매일 약 800만 명이 이용할 만큼 가장 대표적인 교통수단이기 때문에, 지하철을 이용하는 시민들이 느끼는 삶의 만족도와 관련이 없을 수 없다. 특히 수도권에 인구의 절반이 분포된 한국의 경우 인구밀도의 문제가 일반적인 거리에서의 사고뿐만 아니라 교통수단 내외에서 발생할 수 있는 사고들과도 관련성이 높을 수 있으므로 혼잡도를 낮추기 위해 정책적으로 많은 논의가 이루어지고 있다. 따라서 지하철을 이용하는 시민이라면 역사를 확장하거나 리모델링을 하며 환승 시설의 확장과 개선으로 승객의 흐름을 분산하려는 모습, 출퇴근이나 사회적 이슈에 따른 밀집도를 낮추기 위해 배차 간격을 조정하거나 환승 교통수단들을 확장하여 이용 수요를 분산하려는 노력을 종종 볼 수 있다. 또한, 이용 시간대에 따라 요금을 조정하는 등의 방안들도 정책적으로 제시되곤 있지만, 한국은 아직까진 반영하진 않고 있다. 실제 이러한 노력은 전 세계적으로 일반적으로 나타나고 있는 모습이다. 중국은 베이징의 과거 지하철 노선이 확장되면서 운행 속도가 4% 증가되고 혼잡도가 급격히 감소하였다[29]. 그리고 혼잡통행료, 대중교통 확장, 자전거 도로 확장 등의 정책도 교통 혼잡과 대기오염 감소에 긍정적인 영향을 확인하였다[30]. 또한 런던에서는 2003년부터 중심부에 진입하는 차량들에 대해 혼잡통행료를 부과하여 교통량을 10% 감소시키고 배출가스를 줄였으며 교통사고를 40%까지 감소시켰다. 이러한 정책은 뉴욕, 싱가포르, 스톡홀름 등 다른 도시에도 영향을 주고 있다[31]. 그 외에도 여러 문헌

조사와 37명의 전문가 인터뷰 등을 통해 혼잡도 완화를 위한 정책과 전략들을 확인 할 수 있었다[32]. 하지만 전반적으로 교통공학, 도시계획, 교통정책 등을 중심으로 진행되었고, 최근에는 빅데이터와 AI 기반 최적화를 통해 실시간 운행 스케줄이나 혼잡도 예측하여 알려 줌으로써 승객의 편의를 증진시킴으로써 자연스러운 승객의 분산을 유도하려는 노력들이 지속되고 있다.

본 연구는 기존 선행연구와 달리 다음과 같은 5가지 항목에서 기여하고 있다. 첫째, 특정 데이터베이스뿐만 아니라 지하철 관련 공공데이터를 모두 융합하여 혼잡도 예측에 활용하였다. 기존 연구들은 적은 수의 공공데이터만을 활용했지만 본 연구는 총 6개의 데이터베이스를 융합하여 공공데이터의 효용을 뒷받침할 수 있었다. 둘째, 기존 연구들이 비즈니스적으로 바로 활용되기엔 낮은 예측 성능이었지만, 본 연구에선 MSPE 기준 95% 이상의 예측 정확성을 보이며 대중교통 관계자들이 실시간으로 바로 활용할 수 있는 방법론을 달성하였다. 이러한 접근은 다양한 시간대와 노선, 그리고 여러 상황에서도 혼잡도를 효과적으로 예측함으로써 효율적인 자원 배분과 운영 계획 수립에 도움 될 수 있다. 셋째, 높은 예측 성능뿐만 아니라 설명가능한 인공지능을 활용하여 예측 결과를 더욱 쉽게 이해할 수 있도록 제시하였다. 설명가능한 인공지능을 통해 예측 결정 과정과 근거를 시각적으로 제공함으로써, 실제 비즈니스와 정책의 의사결정 과정을 보다 투명하고 신뢰할 수 있게 지원한다. 넷째, 클라우드나 고성능 PC 없이도 누구나 현장에서 쉽게 사용할 수 있는 머신러닝 및 딥러닝 기반 비즈니스 애널리틱스 구조를 제시하였다. 누구나 손쉽게 데이터를 학습하고 활용할 수 있도록 설계되었기에 실용성을 극대화하는 연구다.

본 연구의 XAI 실험 결과에 따르면 “하차인원 > 승차인원 > 출입구 > 섬식여부 > 월요일

> 화요일”의 순서로 혼잡도를 높이며, “환승노선_개수 > 환승유입인원수 > 하선/상선 혼잡도 > 주 > 년도 > 월 > 일요일 > 목요일 > 혼잡도”의 순서 변수들이 혼잡도를 낮추는 요인들로 분석되었다. 따라서 혼잡도를 낮추기 위해서는 하차/승차 인원을 줄이는 것이 가장 근본적인 해결책일 수 있지만, 그 외에도 지하철 노선을 확장하거나 노선간 연결점들을 늘려 환승노선과 환승유입인원수를 늘리는 방법도 활용할 수 있다. 지하철의 출입구를 줄이거나 섬식이 아닌 승강장 플랫폼 형태로 지하철을 개발하는 것이 필요한데, 이것은 환경적 비용적으로 고려가 되어야 하는 부분이라 기존 지하철 환경의 변경 보단 신규 노선들에 반영되면 좋을 수 있는 인사이트로 볼 수 있다. 또한 주의 출근이 몰리는 월요일과 화요일에 특히 혼잡도가 높아지기 때문에 근무의 유연화 문화를 확산하여 혼잡도 개선이 가능할 것이다. 그리고 연초보다 연말로 갈수록 혼잡도가 낮아지는 경향이 있기 때문에 시민들을 대상으로 하는 행사들도 하반기로 배치하는 것이 혼잡도를 낮추는데 기여할 수 있다. 그리고 과거보다 현재로 갈수록 지하철 혼잡도는 낮아지는 추세가 있다. 이는 여러가지 종류의 교통 개발과 정책적 접근이 효과를 가져오는 것으로 판단할 수 있는 근거자료가 될 수 있다. 이처럼 본 연구는 설명 가능한 인공지능을 활용하여 지하철 혼잡도를 실시간으로 빠르게 확인할 수 있는데 도움을 줄 수 있으므로, 서비스 측면에서 시민들에게 빠르고 효과적인 대응책을 마련하는 데 도움이 될 것이다. 대표적 딥러닝 알고리즘의 성능이 높게 나타나고 있어 향후 더욱 정교한 알고리즘으로 성능을 향상시켜 볼 계획이며 추가적으로 시계열 예측으로 확장한다면 실제 미래 전망에도 활용도가 높을것으로 예상된다.


참 고 문 헌

- [1] C. Transportation, “Seoul Transportation in 2022,” Seoul Metropolitan Government, 2023.
- [2] 김승준, “서울시 지하철의 혼잡비용 산정과 정책적 활용방안 | 서울연구원,” 서울연구원, 2016.
- [3] S. Jun and S. Il, “A Study on Improving Subway Crowding Based on Smart Card Data : a Focus on Early Bird Policy Alternative,” *Journal of Information Technology Services*, vol. 19, no. 2, pp. 125-138, 2020, doi: 10.9716/KITS.2020.19.2.138
- [4] 이선희, 천춘근, 정병두, 유병영, and 김은지, “철도 이용객 정보제공 효과평가 방법론 연구 -승강장의 혼잡상황을 고려한 Gate Metering 사례 연구 중심으로-,” *한국ITS학회 논문지*, vol. 14, no. 3, pp. 50-62, 2015, doi: 10.12815/kits.2015.14.3.050
- [5] H. Lee and J. K. Choi, “Development of an Algorithm for Estimating Subway Platform Congestion Using Public Transportation Card Data,” *Journal of the Korean Society for Railway*, vol. 18, no. 3, pp. 270-277, 2015.
- [6] L. Sangjun, S. Seongil, L. Sunghee, and Y. Seongjin, “Estimation of Usable Waiting Areas considering Passenger Behavior on Urban Railway Platforms,” *Journal of Korean Society of Transportation*, vol. 39, no. 6, pp. 721-736, 2021, doi: 10.7470/jkst.2021.39.6.721
- [7] S. Jun and S. Il, “A Study on Improving Subway Crowding Based on Smart Card Data : a Focus on Early Bird Policy Alternative,” *Journal of Information Technology Services*, vol. 19, no. 2, pp. 125-138, 2020, doi: 10.9716/KITS.2020.19.2.138
- [8] 김근원, 김동우, N. Kyoo-Sung, and 이주연, “An Exploratory Study on Improvement Method

- of the Subway Congestion Based Big Data Convergence,” *Journal of Digital Convergence*, vol. 13, no. 2, pp. 35-42, 2015.
- [9] K. Jin, “Subway Congestion Prediction and Recommendation System using Big Data Analysis,” *Journal of Digital Convergence*, vol. 14, no. 11, pp. 289-295, 2016.
- [10] L. Jeong-Hun and J. Hun-Young, “The Impact of Weather Conditions on Transit Ridership Using Quantile Regression Analysis,” *Journal of Korea Planning Association*, vol. 53, no. 4, pp. 95-106, 2018, doi: 10.17208/jkpa.2018.08.53.4.95
- [11] S. Shin, S. Jun, and C. Lee, “A Model for Analyzing Time-Varying Passengers’ Crowdedness Degree of Subway Platforms Using Smart Card Data,” *Journal of Korean Society of Intelligent Transport Systems*, vol. 18, no. 5, pp. 49-63, 2019.
- [12] Y. Liu, Z. Liu, and R. Jia, “DeepPF: A deep learning based architecture for metro passenger flow prediction,” *Transportation Research Part C: Emerging Technologies*, vol. 101, pp. 18-34, 2019, doi: 10.1016/j.trc.2019.01.027
- [13] 권효승, 최창준, 정효석, 송재인, 강민희, and 황기연, “GRU를 이용한 서울시 지하철 구간별 혼잡도 예측 모델 연구,” in *한국ITS학회 학술대회*, 2020, pp. 185-190.
- [14] J. Jang, C. Kim, and M. Park, “Subway Line 2 Congestion Prediction During Rush Hour Based on Machine Learning,” *The Journal of Convergence on Culture Technology*, vol. 9, no. 6, pp. 145-150, 2023.
- [15] S. Park and H. Lee, “지하철 혼잡도 예측을 위한 멀티스트림 하이브리드 딥러닝 프레임워크,” in *대한산업공학회 추계학술대회 논문집*, 2023, pp. 2525-2548.
- [16] J. Hu, “Prediction of short-term passenger flow of subway based on LSTM model,” in *Proceedings of the 3rd International Conference on Computing Innovation and Applied Physics*, 2023, pp. 237-244, doi: 10.54254/2753-8818/13/20240853
- [17] K. Kim, S. Park, S. Choi, and Y. Kim, “A Study on Dynamic Analysis and Prediction Modeling of Subway Station Congestion Changes Using Deep Learning Analysis,” in *Proceedings of Symposium of the Korean Institute of communications and Information Sciences*, 2024, pp. 1192-1194.
- [18] X. Tian, C. Zhang, and B. Zheng, “Fine-Grained Passenger Load Prediction inside Metro Network via Smart Card Data,” *International Journal of Intelligent Systems*, vol. 2024, no. 1, pp. 6643018, 2024, doi: 10.1155/2024/6643018
- [19] L. Zhenwei et al., “A Hybrid Method for Predicting Traffic Congestion during Peak Hours in the Subway System of Shenzhen,” *Sensors*, vol. 20, no. 1, pp. 150, 2019, doi: 10.3390/s20010150
- [20] Y. Li, R. Yu, C. Shahabi, and Y. Liu, “Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting,” in *ICLR*, 2018,.
- [21] P. Yulong, R. Songmin, W. Wanjiao, and D. Chuntong, “Bus-Passenger-Flow Prediction Model Based on WPD, Attention Mechanism, and Bi-LSTM,” *Sustainability*, vol. 15, no. 20, pp. 14889, 2023, doi: 10.3390/su152014889
- [22] M. Leticia, C. Ramón, R. Carlos, and S. M. Manuel, “Deep Learning XAI for Bus Passenger Forecasting: A Use Case in Spain,” *Mathematics*, vol. 10, no. 9, pp. 1428, 2022, doi: 10.3390/math10091428
- [23] L. Sanggwon, “Application of Interpretable Machine Learning to Explore Associations between Transportation Accessibility and Population and Business Density,” *Journal of*


- The Korean Regional Development Association*, vol. 35, no. 1, pp. 105-120, 2023.
- [24] 홍석준 and 노병준, "Trajectory Prediction and Interpretation of Urban Driving Vehicle Lane Changes in Drone View : using Deep Learning Model and XAI Techniques," in *한국ITS학회/학술대회*, 2024, pp. 830-832.
- [25] K. Lee, Y. Lee, I. Kim, S. Soo, and Y. Ilsoo, "Development of a Freight Driver Travel Identification Model Using XAI Techniques Based on Trip Chain Data," *Journal of Korean Society of Intelligent Transport Systems*, vol. 23, no. 6, pp. 43-62, 2024, doi: 10.12815/kits.2024.23.6.43
- [26] O. Ibrahim, "Improving traffic accident severity prediction using MobileNet transfer learning model and SHAP XAI technique," *PLOS ONE*, vol. 19, no. 4, pp. e0300640, 2024, doi: 10.1371/journal.pone.0300640
- [27] A. Adadi and M. Berrada, "Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)," *IEEE Access*, vol. 6, pp. 52138-52160, 2018, doi: 10.1109/ACCESS.2018.2870052
- [28] Y. Eun, S. Bin, J. Yun, and J. Hwan, "Study on credit rating model using explainable AI," *Journal of the Korean Data And Information Science Society*, vol. 32, no. 2, pp. 283-295, 2021, doi: 10.7465/jkdi.2021.32.2.283
- [29] J. Yang, S. Chen, P. Qin, F. Lu, and A. A., "The effect of subway expansions on vehicle congestion: Evidence from Beijing," *Journal of Environmental Economics and Management*, vol. 88, pp. 114-133, 2018, doi: 10.1016/j.jeem.2017.09.007
- [30] P. Jia and S. Li, "Evaluating Urban Transportation Policies," *National Bureau of Economic Research*, 2023.
- [31] A. Davies, "London's Congestion Pricing Plan Is Saving Lives," *WIRED*, 2015.
- [32] C. for, "Development of Comprehensive Roadmap and Resource Guide Towards Congestion Reduction," *Medium*, 2025.

저 자 소 개



박 재 흥 (Jae-Heung Park)

· 2025년 8월 : 인천대학교
무역학부 (무역학사), 컴퓨터
공학부 (공학사)
<관심분야> : 수요 예측, 머신러
닝, 딥러닝, 데이터마이닝, LLM



김 경 원 (Kyung-Won Kim)

· 2007년 2월 : 한양대학교 수학과 및 물리학 (이학사)
· 2010년 2월 : 서울대학교 계산과학과 (이학석사)
· 2014년 2월 : 서울대학교 산업공학과 (공학박사)
· 2014년 4월~2017년 8월 : 삼성전자 영상디스플레이사업부 빅데이터랩 (데이터사이언티스트)
· 2017년 9월~2021년 2월 : 삼성리서치 글로벌인공지능센터 빅데이터팀 (데이터사이언티스트)
· 2021년 3월~현재 : 인천대학교 글로벌경영대학 무역학부 교수
<관심분야> : 비즈니스애널리틱스, 시계열 텍스트 분석, 수요예측, 소셜AI, AI의사결정