

AI로 읽는 글로벌 이슈  
: 한국 환율 예측을 위한 이벤트와 감성 융합

Reading Global Issues with AI  
: Event and Sentiment Fusion for Exchange Rate  
Prediction in Korea

박재홍<sup>1</sup>, 김경원<sup>2</sup>

Jaeheung Park, Kyungwon Kim

2025년 11월 7일

---

<sup>1</sup> 제1저자, 무역학부, 인천대학교, 인천, 대한민국; Email: james2p@inu.ac.kr

<sup>2</sup> 교신저자, 무역학부, 인천대학교, 인천, 대한민국; Email: thekimk.kr@gmail.com

# AI로 읽는 글로벌 이슈

## : 한국 환율 예측을 위한 이벤트와 감성 융합

### 초록

본 연구는 2020~2024년 원/달러 환율을 대상으로, 거시경제 및 금융시장 지표에 뉴스 기반 이벤트(GDELT)와 감성 요약 지표를 결합한 딥러닝 예측모형을 제안하였다. LSTM, GRU, CNN-LSTM, CNN-GRU 네 가지 아키텍처와 다양한 입력 조합(Lookback=5~90일)을 동일한 설계하에 비교한 결과, 시간 창구별로 예측을 지배하는 신호와 최적 구조가 동태적으로 전이되는 패턴이 확인되었다. 단기(5~10일)에서는 감성 중심의 CNN 하이브리드가, 중기(20~30일)에서는 이벤트 및 감성 복합형 CNN-GRU가, 장기(60~90일)에서는 사건 중심의 LSTM이 최적 성능을 보였다. 변수 중요도 분석 결과, 금, 유가 등의 실물자산과 미국 금리와 주가지수 등의 거시 및 금융 변수, 그리고 뉴스량과 감성 톤의 변동이 환율 예측의 핵심 설명 요인으로 확인되었다. 시각화 결과 제안된 모델은 실제 환율의 방향성과 추세를 안정적으로 재현하였으며, 이는 이벤트와 감성 정보의 결합이 환율 예측의 정확성과 해석 가능성을 동시에 향상시킬 수 있음을 실증적으로 보여준다.

주제어: 환율 예측, 시계열 구조 전이, 딥러닝 하이브리드, 글로벌 이벤트, 뉴스 감성 분석

## I. 서론

환율(Exchange rate)은 한 국가의 통화 가치가 타국 통화 대비 어느 수준에 있는지를 보여주는 핵심 거시지표이자, 실물경제와 금융시장을 연결하는 교환 메커니즘이다. 한국은행(2023)에 따르면 환율은 외환시장의 수요·공급 균형뿐 아니라 인플레이션, 금리, 무역수지, 생산성 등 광범위한 거시경제 요인에 의해 장기적으로 결정되며, 단기적으로는 투자자 기대, 글로벌 자본 이동, 그리고 뉴스와 정책 이벤트와 같은 정보 충격(Information Shocks)에 의해 크게 요동친다. 김인준, 이영섭 (2019)에 의하면 이는 두 나라 통화의 상대적 가치를 보여주는 지표로, 오늘날 거의 모든 경제 활동이 국제 거래와 밀접하게 연계되어 있기 때문에 개인의 일상생활 뿐 아니라 기업 경영, 국가 경제 운영에 이르기까지 필수적인 정보로 기능한다. 따라서 환율은 단순한 가격지표가 아니라 경제 펀더멘털, 정책 불확실성, 시장 심리의 복합적 상호작용을 반영하는 동태적 시스템(Dynamic System)으로 해석된다.

특히 원/달러 환율은 한국의 대외거래 구조와 거시정책에 직결되는 핵심 변수로, 수출입 가격 경쟁력, 외국인 투자 흐름, 물가 수준, 통화정책의 파급경로에 지대한 영향을 미친다. 환율의 미세한 변동은 기업의 수익성과 자산가치, 투자 포트폴리오, 그리고 국가 차원의 외환보유 정책까지 연쇄적으로 영향을 미치며, 이에 따라 환율의 미래 경로를 정밀하게 예측하는 것은 국가경제 안정성과 기업의 재무전략 수립 모두에 필수적인 과제로 인식된다. 그러나 현실의 환율은 종종 랜덤워크(Random Walk)로 묘사될 정도로 예측이 어려우며, 경제 펀더멘털 외에도 지정학적 리스크, 글로벌 유동성, 시장의 비이성적 기대가 복합적으로 작용한다(한국경제, 2023).

한국은행이 정의한 환율의 변동 요인에 따르면 환율은 외환시장의 수요와 공급에 의해 결정되며, 장기적으로는 물가 수준이나 생산성 변화와 같은 경제 여건이 통화 가치에 영향을 미친다. 중기적으로는 대외거래와 거시경제정책이 주요 요인으로 작용하고, 단기적으로는 시장 참가자들의 기대, 주변국 환율 변동, 각종 뉴스에 의해 크게 좌우된다. 특히 시장 참가자들의 기대가 환율 상승 혹은 하락 쪽으로 쏠리면 자기실현적(Self-fulfilling) 거래를 통해 실제 환율 변동을 초래하기도 한다. 예컨대 다수가 환율 상승을 예상할 경우, 환율이 오르기 전에 외환을 선매입하려는 수요가 증가하여 실제로 환율 상승을 유발하게 된다. 또한 뉴스와 같은 정보 역시 시장 참가자들의 기대를 변화시켜 단기

환율 변동에 중요한 영향을 미친다. 실제로 2010년 5월 천안함 침몰조사 결과 발표로 지정학적 리스크가 부각되자 원/달러 환율이 단기간 급등한 사례가 있다. 이와 같은 환경에서 환율의 경로를 정밀하게 예측하는 것은 정책당국의 통화와 재정정책 수립, 기업의 수출입 가격전략 조정, 금융기관의 리스크 관리에 필수적이다. 기존 국내 연구들은 이러한 필요성을 강조해왔다.

기존 연구들은 이러한 복잡성을 정량적으로 설명하기 위해 시계열 기반의 예측 모델을 제시해왔다. 김우식, 한규식 (2021)은 팬데믹 이후 환율 변동성의 구조적 확장을 보고하며 예측모델의 필요성을 강조하였고, 오인정, 김우주 (2022)는 코로나19 구간에서 SARIMA와 ARDL 모델을 비교하여 국면별 성능 차이를 확인하였다. 그러나 다수의 연구가 종가 기반의 전통적 시계열 모델에 한정되어 있으며, 최근 금융시장에서 점차 중요성이 부각되는 뉴스, 이벤트 및 감성과 같은 비정형 정보(Unstructured Information)를 체계적으로 통합한 예측 연구는 여전히 부족하다.

이러한 한계를 보완하기 위해 본 연구는 거시경제 및 금융시장 변수에 더해 뉴스 기반 이벤트(GDELТ)와 감성 요약 지표(Direct Sentiment, News Count)를 결합한 딥러닝 기반 융합 예측모델(Hybrid Deep Learning Model)을 제안한다. 본 연구의 접근은 세 가지 점에서 차별적이다. 첫째, 환율 변동을 단일 시계열로 보지 않고, 시간 창구(Lookback Horizon)에 따라 지배적 신호가 어떻게 전이되는지를 계량적으로 분석한다. 둘째, LSTM, GRU, CNN-LSTM, CNN-GRU 네 가지 아키텍처를 동일한 실험 설계로 비교하여, 단기-중기-장기 예측구간별 최적 구조를 탐색한다. 셋째, 거시 및 금융시장 변수(Macro/Market), 이벤트(Event), 감성(Sentiment)의 상호작용 효과를 검증하여, 환율 예측에서 구조적 요인과 심리적 요인의 결합 메커니즘을 실증적으로 규명한다.

실험 결과, 환율 예측의 지배적 요인은 시간 창구에 따라 동태적으로 전이되었다. 단기(5-10일)에서는 감성(Sentiment) 중심의 CNN 하이브리드 구조가, 중기(20-30일)에서는 이벤트 및 감성 복합형 CNN-GRU가, 장기(60-90일)에서는 사건(Event) 중심의 LSTM이 최적 성능을 보였다. 또한 Permutation Importance 분석 결과, 금(XAU Price)이 환율의 구조적 변동성을 설명하는 핵심 변수로, Direct News Count와 GDELТ 이벤트 빈도가 단기 변동성을 유발하는 주요 요인으로 확인되었다. 이는 정보 확산과 사건 발생이 시장 심리를 매개로 환율의 단기 움직임을 자극하는 반면, 실물자산과 거시 변수는 장기적 추세를 형성한다는

점을 실증적으로 뒷받침한다.

이와 같은 결과는 환율 예측이 단순한 수학적 시계열 문제가 아니라, 시장정보의 비선형적 상호작용을 해석하는 복합적 의사결정 문제임을 시사한다. 따라서 본 연구는 감성 분석(Sentiment Analysis)을 통해 시장참여자의 기대와 정서를 정량화하고, 이를 딥러닝 기반 예측모형에 통합함으로써 심리적 요인과 구조적 요인을 동시에 반영하는 환율 예측의 새로운 패러다임을 제시한다. 이러한 접근은 정책당국의 환율안정 정책 수립, 기업의 환위험 관리, 금융기관의 포트폴리오 조정 등 실무적 의사결정에 실질적 인사이트를 제공하는 재무관리적 의미를 갖는다.

## II. 문헌연구

환율 예측은 오랜 기간 동안 재무관리 및 국제금융 연구의 핵심 주제로 다루어져 왔다. 기존 연구는 주로 거시경제(Macro) 및 금융시장(Financial Market) 변수에 기초한 예측 프레임워크를 중심으로 발전해왔다.

Plakandaras, Papadimitriou, and Gogas (2015)는 원자재, 금속, 주가지수, 금리, 무역지수 등 다차원적 거시 지표를 활용하여 다양한 환율을 예측한 결과, EEMD 기반 비선형 모형이 일간 및 월간 수준에서 우수한 성능을 보임을 보고하였다. Cao et al. (2020) 또한 실물자산 변수(금 및 유가)와 통화공급, CPI, PPI, 산업생산, 기준금리, 인플레이션율, 무역수지, 정책 불확실성 지수를 결합한 DC-LSTM 모델을 통해 ARIMA, SVR, CNN, LSTM을 모두 능가하는 예측력을 입증하였다. 또한, Qureshi (2025)는 USD/INR 환율을 대상으로 금리, 인플레이션율, GDP 성장률, 외환보유액 등 거시경제 펀더멘털 변수를 활용하였다. 비선형적 패턴을 학습하기 위해 다양한 머신러닝 모형을 비교한 결과, Random Forest가 가장 우수한 성과를 나타냈다. 마지막으로 Wang, Wang, Li, and Wang (2021)은 USD/CNY 환율 뿐만 아니라 나스닥, 다우존스, 상하이 종합지수, 항생지수 등 글로벌 주가지수를 독립변수로 결합하였다. CNN, RNN, LSTM 등 여러 모형을 비교한 결과, CNN-TLSTM 모형이 MAPE 0.18945로 가장 높은 예측력을 보였다. 이렇게 기존 환율 예측 연구들은 공통적으로 금리, 물가, 무역수지, 주가지수, 원자재 가격 등 거시경제 및 금융 변수를 중심으로 환율 변동을 설명하고자 했음을 확인할 수 있다. 이러한 연구들은 공통적으로 환율의 장기적 추세가 경제 펀더멘털에 의해 지배된다는 점을 강조하면서도, 최근의 단기 변동성은 비선형적이며 외생적 충격에 민감하게 반응한다는 사실을 시사한다.

국내 연구 또한 이와 유사한 흐름을 보인다. 임현욱, 정승환, 이희수, 오경주 (2021)는 연합인포맥스와 Bloomberg 데이터를 사용하여 금리 및 채권시장 지표를 중심으로 ANN 기반 원/달러 환율 예측을 수행하여 평균 Hit Ratio 50.96%를 기록하였으며, 오인정, 김우주(2022)는 코로나19 구간을 중심으로 SARIMA와 ARDL을 비교하여 국면별 예측 성능의 차이를 실증하였다. 하지만 대부분의 연구는 종가 중심의 단변량 시계열 접근 또는 거시 변수만을 반영한 구조적 모형에 머물러 있으며, 이벤트(Event)나 감성(Sentiment)과 같은 비정형 요인의 동태적 효과를 통합적으로 분석한 시도는 제한적이었다.

이러한 한계를 보완하기 위해 최근 연구들은 외생적 사건 정보와 시장 심리(Sentiment

Factor)를 환율 예측의 새로운 설명 요인으로 통합하기 시작했다. GDELT(Global Database of Events, Language, and Tone)는 전 세계 언론 데이터를 실시간으로 모니터링하여 사건의 유형, 위치, 강도, 감정 톤을 정량화하는 데이터베이스로, 경제 및 금융 분야에서 이벤트 데이터의 시계열화(Time-series Quantification)를 가능하게 하는 새로운 데이터 자원으로 주목받고 있다.

경제 및 금융 분야에서도 GDELT 기반 이벤트 데이터를 예측 변수로 활용한 사례가 있다. Schroeder, Winterbottom, Sitter, and Perdigones (2013)은 ARIMA 모형에 GDELT 데이터를 추가하여 환율 예측 정확도를 약 1% 향상시키고, Gradient Boosting 기반 분류 모델에서는 정확도를 6% 상승시켰으며, Consoli, Tiozzo Pezzoli, and Tosetti (2020)는 유럽 채권시장 분석에서 GDELT 지표가 Nowcasting 모델의 성능을 향상시킨다고 보고하였다. 또한 Blanqué, Ben Slimane, Cherief, Le Guenedal, Sekine, and Stagnol (2022)는 미국 주식시장 예측에서 GDELT 지표는 전통적 거시 경제 모형을 능가하는 설명력 및 예측 성능을 제공함을 실증적으로 제시하였다. 이러한 결과는 이벤트 정보가 거시 변수의 구조적 한계를 보완하며, 시장의 전환점(Turning Point)을 탐지하는 보조신호로 기능할 수 있음을 시사한다.

한편, 시장참여자의 심리적 반응을 정량화하려는 시도도 활발히 이루어지고 있다. Gupta, Ranjan, and Singh (2024)에 따르면 감성 분석(Sentiment Analysis)은 비정형 텍스트에 내재된 정서적 톤을 수치화하여 금융 의사결정에 반영하는 접근으로, 최근 금융 예측의 새로운 축으로 자리 잡고 있다. Cambria, Poria, Gelbukh, and Thelwall (2018)에 의하면 기존 연구에서는 규칙 기반 접근이나 전통적 머신러닝 기법이 주로 활용되었으나, 도메인 의존성, 언어 확장성, 은유·풍자와 같은 복잡한 뉘앙스 처리의 한계가 지속적으로 지적되었다. 이러한 제약을 극복하기 위해 최근에는 Transformer 기반 딥러닝 모델이 적극 도입되었다. 특히 BERT 계열 모델은 양방향 문맥 정보를 활용하여 단어 의미를 정교하게 파악하고, 적은 데이터로도 파인튜닝이 가능하다는 장점이 있다. 따라서, 전통적 규칙 기반 접근의 한계를 지적하며, Transformer 기반 언어모델의 도입이 감성 분석의 정밀도를 비약적으로 향상시켰다고 보고하였다.

특히 Araci (2019)에 따르면 금융 분야에서는 FinBERT와 같이 금융 특화 언어모델이 등장하여 기존 머신러닝 접근 대비 성능이 크게 향상되었으며, Nasiopoulos, Roumeliotis, Sakas, Toudas, and Reklitis (2025)의 FiQA·Financial PhraseBank와 같은 벤치마크에서도

Transformer 기반 모델들이 전통적 방법을 압도하는 성능을 기록하며 금융 도메인에 특화된 감성 추론을 가능하게 하였다. 더 나아가 Shen and Zhang (2024)와 Kang and Choi (2025)는

Shen and Zhang (2024), Kang and Choi (2025)는 GPT-4o와 같은 대규모 언어모델(LLM)이 프롬프트 튜닝이나 미세조정(Few-shot Tuning) 학습만으로도 FinBERT와 동등하거나 기존 금융 특화 모델을 능가하는 수준의 정서 분류 성능을 보인다고 보고하였다. 이에 따라 본 연구는 기존 규칙 기반 혹은 단순 머신러닝 기법 대신, LLM(GPT-4o-mini)을 활용한 고도화된 감성 분석 절차를 설계하였다.

감성 요인의 금융 예측 활용은 주식시장을 중심으로 빠르게 확산되고 있다. Mohan, Mullapudi, Sammeta, Vijayvergia, and Anastasiu (2019)는 Apple, Amazon, Microsoft 등 S&P500 주요 기업의 증가 정보와 함께 국제 뉴스 기사에서 추출한 긍·부정 감성 점수를 독립변수로 사용하였다. 분석 결과, 감성 변수를 포함한 RNN 모델이 MAPE 2.03으로 가장 우수한 성과를 기록함을 보였다. Jing, Wu, and Wang (2021)은 Shanghai Stock Exchange 데이터와 Eastmoney.com 투자자 게시글의 감성 점수를 CNN으로 분류하고, 이를 주가 기술적 지표와 함께 LSTM 모델에 입력하였다. 그 결과 CNN-LSTM 모델이 평균 MAPE 0.0449로 가장 뛰어난 예측력을 보여, 투자자 심리 반영의 효과성을 입증하였다. 또한 정가연, 이혁제, 이준영, 이제혁 (2024)은 네이버 증권 뉴스, 한국은행 API, Naver DATALAB 데이터를 활용하여 코스피, S&P500, 유가, 금값, 원/엔 환율, 금리 등 거시 및 금융시장 변수와 함께 KLUE-BERT 기반 뉴스 감성 점수, 코스피 검색 빈도수 등 시장 심리 변수를 결합하였다. 실험 결과, CNN-GRU 모델이 MAPE 1.38%로 가장 낮아 감성 분석의 유용성을 보여주었다. 이러한 연구들은 전통적인 금융 변수에 뉴스 및 게시글 감성 점수를 결합하는 융합적 독립변수 구성이 주가 예측 정확도를 높이거나 단기적 변동성을 설명하는데 실질적 기여를 한다는 점을 공통적으로 지적한다.

환율 예측에서도 최근에는 감성 분석을 접목한 연구가 점차 확산되고 있다. Ding, Shi, Deng, Farooq, Dewi, Abdullah, and Malek (2024)은 Investing.com과 ForexEmpire의 뉴스 및 댓글 데이터를 기반으로 감성 점수를 산출하였다. 이들은 해당 감성 지표를 USD/CAD, USD/MXN, USD/CNY, USD/JPY, USD/KRW 등 주요 교차환율, 원자재 가격(유가, 금, 구리, 옥수수 등), 글로벌 지수(S&P500, EuroStoxx50, VIX), 채권수익률(미국·유로존 10년물)과 같은 거시·금융 변수와 결합하였다. 다양한 모형을 비교한 결과, PSO-LSTM 모델이 RMSE



0.0958로 가장 높은 성능을 기록하였다. 이러한 결과는 환율 예측에서도 단순한 거시경제 지표만으로 설명하기 어려운 단기 변동성을 뉴스 및 댓글에 담긴 시장 심리 변수가 효과적으로 보완할 수 있음을 실증적으로 보여준다.

<표 1>에 정리된 선행연구를 종합하면, 다음과 같은 시사점을 도출할 수 있다. 첫째, 환율 예측에서는 여전히 금리, 물가, 무역수지, 원자재 가격, 주가지수 등 거시경제 및 금융 변수가 핵심적 설명 변수로 기능하고 있다. 이러한 거시경제 및 금융시장 변수는 여전히 환율 변동의 구조적 기반으로 작용하며, 이는 장기 추세 예측에서 필수적 요인으로 남아 있다. 둘째, 최근 연구들은 뉴스, 투자자 게시글, 댓글 등 비정형 텍스트 데이터에서 추출한 감정 점수를 독립변수로 추가하여 예측 성능을 향상시키고 있으며, 이는 국면 전환이나 정책 불확실성 국면에서 환율 방향성을 조기 포착할 수 있는 보완적 예측 신호로 기능한다. 셋째, 감성 분석을 결합한 환율 예측 연구는 아직 초기 단계에 있으나, 뉴스 및 비정형 텍스트 데이터를 통해 시장참여자의 기대와 심리적 편향을 정량화함으로써, 단기적 변동성 예측력의 실질적 개선을 가능하게 한다.

따라서 본 연구는 이러한 시사점을 바탕으로, 기존 거시 및 금융시장 변수 중심의 예측틀을 확장하여, GDELT 기반 글로벌 이벤트 지표, LLM 기반 감성 분석 점수를 통합한 딥러닝 융합모델 기반 원/달러 환율 예측 모델을 제안한다. 이를 통해 본 연구는 환율 예측을 구조적 요인과 심리적 요인의 통합적 의사결정 문제로 재정의하고, 단기 변동성과 장기 추세를 동시에 포착할 수 있는 예측 패러다임을 제시한다.

**<표 1> 환율 예측 및 주가 예측과 감성 분석을 활용한 선행연구 분석 방향과 성능 요약**

| 연구<br>구<br>목<br>적 | 연구자(연도)                            | 데이터 소스  | 데이터 기간    | 주요 독립변수  | 방법론  | 성능  |
|-------------------|------------------------------------|---------|-----------|--|--|---|
| 환<br>율<br>예<br>측  | Plakandaras<br>et al.(2015)<br>[5] | 미기재     | 1999~2011 | 원자재(19),<br>금속(10), 주<br>가지수(7),<br>금리(11), 무<br>역·거시지표<br>등 | ARIMA, GARCH,<br>AR-NN, MARS-<br>NN, SVR, EEMD<br>결합 | 일간:<br>EEMD-<br>MARS-<br>SVR,<br>MARS-NN<br>우수 /<br>월간:<br>EEMD-AR-<br>SVR 우수 |
|                   | 임현욱 외                              | 연합인포맥스, | 2008~2020 | IRS 금리,  | ANN, LR, DT  | ANN 평균  |

|   |                               |  |               |  |   |   |
|---|-------------------------------|--|---------------|--|---|---|
|   | (2021)<br>[6]                 | Bloomberg                              |               | KTB 수익률,<br>본드 스왑 스<br>프레드   |   | Hit<br>Ratio<br>50.96%                          |
|   | Cao et<br>al.(2020)<br>[7]    | 미기재                                    | 2016.6~2019.4 | 유가, 금값,<br>CPI, PPI, 산<br>업생산, 기준<br>금리, 무역수<br>지, 정책 불<br>확실성 지수<br>등 | ARIMA, SVR,<br>CNN, LSTM,<br>DC-LSTM              | DC-LSTM<br>MAE<br>0.0145                        |
|   | Qureshi(2025)<br>[8]          | FRED, IMF,<br>World Bank 등             | 2015~2023     | 금리, 인플레<br>이션율, GDP<br>성장률, 외환<br>보유액                                  | ARIMA, RW,<br>RF, SVM                             | RF RMSE<br>0.029                                |
|   | Wang et<br>al.(2021)<br>[9]   | Wind DB                                | 2006~2020     | USD/CNY, 나<br>스닥, 다우,<br>상하이, 항셱<br>등 지수                               | MLP, CNN,<br>RNN, LSTM,<br>CNN-LSTM,<br>CNN-TLSTM | CNN-<br>TLSTM<br>MAPE<br>0.18945                |
| 주<br>가<br>예<br>측<br>+<br>감<br>성<br>분<br>석 | Mohan et<br>al.(2019)<br>[10] | 해외 뉴스 웹사<br>이트                         | 2013~2017     | S&P500 기업<br>종가, 뉴스<br>감정  | ARIMA,<br>Prophet, RNN                            | RNN-pp<br>MAPE<br>2.03                          |
|   | Jing et<br>al.(2021)<br>[11]  | SSE,<br>Eastmoney.com                  | 2017~2019     | 기술적 지<br>표, 게시글<br>감정  | CNN+LSTM  | MAPE<br>0.0449                                  |
|   | 정가연 외<br>(2024)<br>[12]       | 네이버뉴스,<br>KOSPI,<br>DATALAB, 한은<br>API | 2021~2023     | 코스피 ·<br>S&P500, 유<br>가, 금값, 원<br>/엔 환율, 금<br>리, 검색 빈<br>도, 감정 점<br>수  | LSTM, GRU,<br>CNN-LSTM,<br>CNN-GRU                | CNN-GRU<br>+ KLUE-<br>BERT 감<br>정 MAPE<br>1.38% |
| 환<br>율<br>예<br>측<br>+<br>감<br>성<br>분<br>석 | Ding et<br>al.(2025)<br>[13]  | Investing.com,<br>ForexEmpire          | 2016~2024     | 뉴스 · 댓글<br>감정, 교차환<br>율, 원자재,<br>글로벌 지수,<br>채권수익률                      | PSO-LSTM,<br>SVM, GRU,<br>VAR,<br>ARIMA/GARCH     | PSO-LSTM<br>RMSE<br>0.0958                      |

### Ⅲ. 데이터 및 방법론

#### 1. 종속변수 데이터

본 연구는 2020년 1월부터 2024년 12월까지의 일별 원/달러 환율 증가를 예측 대상으로 설정하였다. 선택된 시기는 코로나19 팬데믹의 발생과 그로 인한 경제적 충격, 글로벌 통화정책의 급격한 전환, 그리고 여러 지정학적 리스크가 동시다발적으로 나타난 시기이기 때문에, 환율 변동성이 경제에 미친 영향을 분석하기에 적합하다. 2020년 이후 원/달러 환율은 팬데믹 초기에 급락한 후, 2021년에는 저점 국면을 경험했고, 2022년에는 미국 연방준비제도의 초고속 금리 인상과 한미 금리 차 확대, 국내 정치와 정책 변화, 러시아 및 우크라이나 전쟁 등의 외적 요인들이 복합적으로 작용하며 큰 폭으로 상승하였다.

특히 2020년과 2021년, 2022년 사이의 환율 추이는 다양한 경제적 요인들이 결합된 결과로, 매우 높은 변동성을 보였다. [그림 1]에서 확인할 수 있듯이, 2021년 초 약 1,070원 수준까지 환율이 하락한 뒤, 2022년 5월에는 1,300원 이상으로 급등하였다. 이는 단순히 환율 수준만이 아니라, 변동성 또한 급격히 확대된 시점을 의미한다. 예를 들어, 2021년 상반기 일평균 환율 등락폭은  $\pm 5$ 원에 불과했으나, 2022년 상반기에는  $\pm 15$ 원으로 크게 확대되었으며, 일간 표준편차 기준 환율 변동성 지표도 같은 기간 동안 0.4%에서 1.2%로 세 배 이상 증가하였다. 환율 변동성의 급증은 한국 경제에 중대한 영향을 미쳤다. 특히 2022년에는 사상 최대의 무역수지 적자가 발생하고, 원화 약세가 지속되며 수입물가 상승, 내수 위축, 소비심리 악화 등의 부정적인 경제적 효과를 불러왔다. 반면, 수출 기업에는 단기적으로 경쟁력이 제공되었으나, 환 헤지 비용이 전년 대비 35% 증가하며 중소기업을 중심으로 금융비용 부담이 커졌다.



[그림 1] 종속변수인 원/달러 환율 추이

## 2. 독립변수 데이터

원/달러 환율 예측을 위한 독립변수는 기존 환율 예측 연구에서 사용된 주요 경제적 요인을 바탕으로 설정하되, 환율 변동성의 구조적 요인과 시장 심리적 요인도 동시에 반영하도록 설계되었다.

환율 예측에 관한 기존 연구는 데이터 구성과 방법론적 설계 측면에서 꾸준히 발전해왔다. 초기 연구들은 주로 거시경제 및 금융시장 지표(Macro-Financial Indicators)를 중심으로 환율의 구조적 변동성을 설명하고자 했다. 예를 들어, Plakandaras, Papadimitriou, and Gogas (2015)는 원자재 가격, 금속, 주가지수, 금리, 무역 및 거시 변수 등 60여 개의 다차원 지표를 활용하여 환율을 예측하고, EEMD 기반 비선형 모형이 일간 및 월간 수준에서 가장 우수한 성능을 보였다고 보고하였다. 임현욱, 정승환, 이희수, 오경주 (2021)는 금리 및 채권시장 변수를 중심으로 한 연구를 진행하였다. 또한, Cao, Zhu, and Wang (2020)은 유가, 금 가격, M1, M2, CPI, PPI 등의 거시지표를 활용했으며, Qureshi (2025)는 금리, 인플레이션율, GDP 성장률, 외환보유액 등을 핵심 변수로 설정하였다. Wang, Wang, Li, and Wang (2021)은 USD/CNY 환율과 함께 주요 글로벌 주가지수를 포함하여 국제적 요인을 반영하였다. 이러한 연구들은 공통적으로 거시 및 금융시장 변수군이 환율의 구조적 변동을 설명하는 핵심 기반 신호로 작용함을 실증하였다.

한편, 최근에는 환율 예측에 비정형 정보(Unstructured Information)를 통합하려는 시도가 활발히 이루어지고 있다. 특히 시장 참여자의 기대와 정서를 반영하기 위한 감성

분석(Sentiment Analysis) 기반 심리 변수화가 주요 연구 흐름으로 자리 잡고 있다. Mohan, Mullapudi, Sammeta, Vijayvergia, and Anastasiu (2019)는 국제 뉴스 기사에서 추출한 감정 점수를 S&P500 주가 예측에 반영하였고, Jing, Wu, and Wang (2021)은 투자자 게시글의 감정을 CNN 기반 분류기로 분석하여 주가 예측에 활용하였다. 정가연, 이혁제, 이준영, 이제혁 (2024)은 KLUE-BERT 기반 뉴스 감정 점수를 거시경제 변수와 결합하여 예측 정확도를 높였고, Ding, Shi, Deng, Farooq, Dewi, Abdullah, and Malek (2024)은 환율 관련 뉴스와 댓글 감성을 결합하여 환율 예측 성능을 향상시켰다. 이러한 결과는 환율이 단순한 거시 펀더멘털뿐 아니라, 시장 참여자의 심리적 반응과 정보 확산 정도에 의해 단기적으로 조정된다는 점을 실증적으로 보여준다.

본 연구는 기존 연구의 방법론을 바탕으로, 주요 독립변수들을 확장하여 설정하였다. 종속변수로 원/달러 환율을 설정하고, 경쟁적인 환율 변동성을 반영하기 위해 USD/JPY와 USD/CNY를 교차환율 변수로 추가하였다. 또한, 국내외 주요 주식시장 지표인 KOSPI, KOSDAQ, 다우존스, S&P500을 자본 흐름과 위험 선호도에 대한 영향을 고려하여 포함하였다. 원자재 변수로는 WTI 유가, 금, 구리, 니켈, 알루미늄을 채택하여 글로벌 경제 사이클과 인플레이션 기대를 반영하였으며, 거시경제 변수로는 한국과 미국의 정책금리, 소비자물가지수(CPI), 생산자물가지수(PPI), 경상수지, 통화량(M1, M2)을 포함하여 환율 결정에 중요한 금리 차, 물가 수준, 대외 거래, 유동성 등을 반영하였다. 또한 리스크 지표로는 VIX, OVX, KSVKOSPI를 포함하여 금융시장의 불확실성과 투자자의 위험회피 성향을 측정하였다.

### 3. 파생변수 데이터

#### 1) 이벤트 데이터

본 연구에서는 GDELT에서 추출한 다섯 가지 핵심 이벤트 기반 변수를 활용하였다. GDELT는 전 세계적으로 발생하는 다양한 사건 및 뉴스의 텍스트 데이터를 기반으로 사건들의 속성(예: 장소, 시간, 관련된 국가 등)을 기록하는 데이터베이스로, 이를 통해 다음과 같은 변수들을 정의하였다: (1) 전체 이벤트 수, (2) 평균 감성 톤, (3) 한국 관련 이벤트 톤, (4) 전체 문서 수, (5) 한국 관련 문서 수이다. 이러한 이벤트 지표는 기존의 거시적 구조적 요인(예: 금리, 주가, 원자재 등) 외에 “사건 기반 리스크 및 심리적

충격”을 반영할 수 있는 변수로서, 본 연구의 독창성을 강조하는 중요한 요소이다.

이벤트 수와 관련된 변수들은 주로 뉴스와 같은 외부 사건이 경제 및 금융시장에 미치는 영향을 반영하는 데 사용된다. 예를 들어, 경제 위기나 정치적 불안정성 등 사건 기반 리스크가 환율 변동성에 미치는 영향을 포착할 수 있다. 평균 감성 톤과 한국 관련 이벤트 톤은 각 사건이나 뉴스의 감성을 수치화하여, 특정 사건이나 뉴스가 환율에 미치는 영향을 심리적 측면에서 분석할 수 있는 기반을 제공한다. 또한, 문서 수 변수는 뉴스의 빈도나 그 영향을 반영하여 환율 예측에 중요한 역할을 할 수 있다.

이러한 이벤트 기반 변수는 본 연구가 다루고 있는 환율 변동성 예측에 있어 “사건 발생에 따른 경제적 반응”을 통합적으로 반영할 수 있는 기회를 제공하며, 기존 연구에서 주로 다루어진 금리나 원자재 가격 같은 전통적인 지표와는 다른 시각에서 변동성의 원인을 분석하는 데 기여한다.

## 2) 감성분석 데이터

본 연구의 뉴스 감성 분석 데이터는 네이버 금융 뉴스의 “환율” 섹션에서 2020년 1월 1일부터 2024년 12월 31일까지 총 35,633건의 기사를 수집하여 활용하였다. 수집된 원문은 정규표현식을 사용하여 대괄호, 소괄호 내 불필요한 문구, 이메일 주소, 광고성 표현, 그리고 “=” 기호 이전의 문장 등을 제거하여 정제하였다. 또한, 제목과 본문이 동일한 중복 기사나 내용이 비어 있거나 공백만 포함된 기사는 분석 목적에 맞지 않기 때문에 제외하였다. 이를 통해 데이터의 품질을 높이고, 불필요한 정보 노이즈를 최소화하였다.

정제된 뉴스는 GPT-4o-mini를 활용하여 원/달러 환율과의 관련성을 기준으로 세부 분류를 진행하였다. 그 결과, 뉴스는 크게 세 가지 범주로 구분되었다: 원/달러 환율과 직접적으로 관련된 뉴스 22,756건, 간접적으로 관련된 뉴스 7,320건, 그리고 관련이 없는 뉴스 5,557건으로 나누어졌다. 이 과정에서 “직접 및 간접 관련 뉴스”에 대해 추가적인 전처리를 수행하여 감성 분석의 정확성을 더욱 높였다.

뉴스 본문은 길이가 다양하고, 종종 불필요한 수식어, 문맥적 중복, 장황한 서술을 포함하고 있기 때문에 이를 그대로 감성 분석에 활용할 경우 모델의 입력 효율성과 분석 정확도가 떨어질 수 있다. 따라서 본 연구에서는 감성 분석 전처리 과정의 일환으로 뉴스

본문 요약을 수행하였다. 요약 모델은 HuggingFace Hub에서 제공되는 여러 한국어 요약 모델 중에서 연구 당시 다운로드 상위 목록에 있는 mT5-multilingual-XLSum, t5-base-korean-summarization, KoBART-summary-v3 세 가지 모델을 비교하였다. 성능 평가는 AI Hub 한국어 문서 요약(신문기사) 데이터셋을 사용하였으며, ROUGE-1, ROUGE-2, ROUGE-L 지표를 통해 평가하였다. Araci (2019)에 의하면 ROUGE는 "Recall-Oriented Understudy of Gisting Evaluation"의 약자로, 텍스트 요약의 품질을 평가하는 데 널리 사용되는 지표 집합이다.

본 연구에서는 KoBART-summary-v3 모델이 모든 ROUGE 지표에서 가장 높은 성능을 기록하여 최종적으로 요약 모델로 채택하였다. 구체적으로 ROUGE-1, ROUGE-2, ROUGE-L F1 점수는 각각 0.4128, 0.1632, 0.3835로 나타났으며, 이는 다른 모델에 비해 상대적으로 높은 수준이었다. ROUGE-1은 단어 수준의 중복 정도를 나타내며 원문이 핵심 어휘를 얼마나 잘 포함했는지 평가한다. ROUGE-2는 연속된 2-gram의 중복을 기준으로 문맥적 연결성과 유창성을 간접적으로 반영한다. Barbella, Tortora (2022)에 따르면 ROUGE-L은 가장 긴 공통 부분수열을 기준으로 요약이 원문의 전체 문장 구조와 맥락을 얼마나 잘 보존하는지에 대한 품질을 평가한다. Dalal, Ranjan, Bopaiah, Chembachere, Steiger, Burns, and Daswani (2024)에 따르면 일반적으로 ROUGE-1 F1 점수가 0.5 이상이면 높은 성능으로 판단할 수 있고, ROUGE-2 F1 는 0.4 이상인 경우, 그리고 ROUGE-L F1은 0.5 이상이 일반적으로 높게 판단될 수 있다. 다만 이런 기준은 언어, 도메인, 요약 길이, 참조 요약의 수 등에 따라 매우 달라지므로 절대적 기준보다는 비교 맥락에서 참고하는 지침으로 활용된다. 이 지표들이 높은 점수를 기록한 모델은 문맥을 잘 보존하면서도 원문 내용을 간결하게 요약할 수 있음을 시사한다.

감성 분석은 GPT-4o-mini 기반의 대형 언어 모델(LLM)을 활용한 프롬프트 분류 방식으로 수행되었으며, 감성 라벨 체계는 환율 변동의 금융적 맥락을 반영하여 정의되었다. 긍정적인 감성은 원/달러 환율 하락(원화 강세), 위험 선호 확대, 완화적 환경을 의미하며, 부정적인 감성은 환율 상승(원화 약세), 위험 회피 확대, 긴축적 환경을 의미한다. 중립 감성은 환율 방향에 대한 명확한 판단이 어려운 경우를 나타낸다. GPT-4o-mini에는 few-shot 프롬프트 튜닝을 적용하여, 별도의 파인튜닝 없이 금융 문맥에 특화된 감성 분류가 가능하도록 하였다. 분류 결과는 긍정=+1, 중립=0, 부정=-1로 수치화하였으며, 이를 기반으로 날짜별 평균 감성 점수를 산출하여 일별 감성 지표(Daily Sentiment Index)를 구축하였다.

분석의 세분화를 위해 뉴스의 환율 관련성을 기준으로 세 가지 일별 변수 세트를 생성하였다: (1) 직접적인 환율 뉴스의 일별 평균 감성 점수 및 기사 수, (2) 간접적인 환율 뉴스의 일별 평균 감성 점수 및 기사 수, (3) 두 범주를 모두 포함한 전체 뉴스의 일별 감성 점수 및 기사 수. 이러한 세분화된 감성 지표는 후속 환율 예측 모델의 중요한 입력 변수로 활용되었다.

#### 4. 데이터 전처리 및 통계량

결과적으로 본 연구는 거시경제 지표, 금융시장 지표, 원자재 가격, 리스크 변수뿐만 아니라 이벤트 기반 변수와 뉴스 및 댓글 감성 지표까지 포괄하여, 환율 변동의 구조적 요인과 단기 시장 심리 요인을 동시에 고려하는 통합적 예측 프레임워크를 구축하고자 하였다. 이 연구는 기존의 전통적인 예측 변수들과 함께 사건 기반의 리스크 및 심리적 충격을 반영하는 새로운 변수를 도입함으로써 예측 성능을 향상시키는 것을 목표로 한다.

<표 2>는 본 연구에서 사용된 주요 데이터를 요약한 것이다. 목표변수인 원/달러 환율(KRW/USD)을 중심으로, 교차환율, 국내외 주식지수, 원자재, 거시지표, 리스크지표, 그리고 사건과 심리를 측정하는 이벤트와 감정(네이버 뉴스) 정보까지 총 8개 블록으로 구성하였다. 월 단위로 제공되는 거시지표는 발표 기준을 반영한 대표값으로 일 단위 프레임에 확장하여, 모든 변수가 일 단위 시점에서 일관되게 모델에 투입되도록 동기화하였다. 이와 같은 구성은 환율을 움직이는 구조적 요인과 단기 심리와 사건 요인을 동시에 포착하는 통합적 예측 프레임워크라는 점에서 의의가 있다.

<표 2> 딥러닝 융합모델 기반 원/달러 환율 예측에 사용한 데이터

| 대분류   | 출처            | 데이터명             | 기간             | 단위 | 추출 변수 | 활용 변수                  |
|-------|---------------|------------------|----------------|----|-------|------------------------|
| 목표 변수 | Yahoo Finance | KRW/USD          | 2020.1-2024.12 | 일  | 종가    | Target (원/달러 환율)       |
| 교차 환율 | Yahoo Finance | USD/JPY, USD/CNY | 2020.1-2024.12 | 일  | 종가    | USD/JPY 종가, USD/CNY 종가 |
| 국내외 주 | Investing.com | KOSPI, KOSDAQ,   | 2020.1-        | 일  | 종가, 거 | KOSPI 종가               |



|            |                                    |   |                    |   |  |   |
|------------|------------------------------------|---|--------------------|---|--|---|
| 식지수        |                                    | 다우존스,<br>S&P500   | 2024.12            |   | 래량   | · 거래량,<br>KOSDAQ 종<br>가· 거래<br>량, 다우존<br>스 종가,<br>S&P500 종<br>가 |
| 원자재        | Yahoo<br>Finance,<br>Investing.com | WTI, 금(XAU),<br>구리, 니켈, 알<br>루미늄  | 2020.1-<br>2024.12 | 일 | 종가   | WTI 종가,<br>금, 구리,<br>알루미늄,<br>니켈 종가                             |
| 거시 지표      | ECOS, FRED,<br>통계청, 한국<br>은행       | 정책금리, CPI,<br>PPI, 경상수지,<br>통화량(M1, M2)                                       | 2020.1-<br>2024.12 | 월 | 한국/미국<br>정책금리,<br>소비자물<br>가지수,<br>생산자물<br>가지수,<br>경상수지,<br>M1, M2  | 동일  |
| 리스크 지<br>표 | Yahoo Finance                      | VIX, MOVE,<br>OVX, KSVKOSPI   | 2020.1-<br>2024.12 | 일 | 주식·채<br>권·유가<br>변동성,<br>코스피 불<br>안 지수                              | 동일  |
| 이벤트 지<br>표 | GDELT                              | events_cnt,<br>tone_mean,<br>tone_kor_mean,<br>gkg_doc_cnt,<br>gkg_kr_loc_cnt | 2020.1-<br>2024.12 | 일 | 이벤트<br>수, 평균<br>톤, 한국<br>관련 톤,<br>전체 GKG<br>문서 수,<br>한국 관련<br>문서 수 | 동일  |
| 감정 지표      | Naver News                         | 환율 관련 뉴스  | 2020.1-<br>2024.12 | 일 | 뉴스 감정<br>점수  | 일일 감정<br>점수 평균,<br>뉴스 개수  |

<표 3>은 본 연구에서 사용된 데이터의 일 단위로 정렬된 최종 통합 패널의 기술통계량을 제시한다(N=1,186). 환율 증가의 평균과 중앙값은 각각 약 1,256원과 1,265원으로, 상단 꼬리가 두터운 분포를 보인다(최대 1,472원). 시장과 리스크 지표는 코로나19와 에너지 쇼크 국면을 반영해 분산이 크게 확대되었는데, VIX와 OVX의 최대치는 각각 82.69와 325.15로 스트레스 피크를 확인할 수 있다.

원자재 관련 변수의 단위는 국제 표준에 따라 산정되었으며, WTI 원유 가격은 배럴(USD/barrel), 금 가격은 트로이온스(USD/troy ounce), 구리와 알루미늄 가격은 톤(USD/metric ton) 단위로 표시된다. 이는 에너지 및 금속 원자재 가격의 국제 거래

기준을 반영한 것으로, 환율 및 금융시장 변수와 함께 글로벌 인플레이션 압력과 상품시장 변동성을 측정하는 지표로 활용된다.

이벤트와 문서 수는 평균적으로 큰 규모를 보이지만 톤 지표는 음(-)의 편향을 나타내며, 뉴스 감정지표는 일평균이 0 부근의 약한 음수로 나타난다. 또한 직접 관련 뉴스의 일평균 기사 수가 간접 관련보다 높아, 환율 관련 보도의 집중적 생산이 관측된다.

<표 3> 최종 융합 데이터 변수들의 통계량 요약 (N, Mean, Std, Min, Q1, Q2, Q3, Max)

| 변수명          | Count | Mean     | Std      | Min      | 25%      | 50%      | 76%      | Max      |
|--------------|-------|----------|----------|----------|----------|----------|----------|----------|
| 원/달러 환율 증가   | 1186  | 1256.283 | 93.74322 | 1083.53  | 1181.822 | 1265.61  | 1333.02  | 1472.5   |
| 원/달러 환율 시가   | 1186  | 1256.633 | 93.7873  | 1083.87  | 1182.46  | 1266.325 | 1333.395 | 1471.1   |
| 코스피 지수       | 1186  | 2596.073 | 339.2823 | 1457.64  | 2399.31  | 2568.48  | 2758.637 | 3305.21  |
| 코스피 거래량      | 1186  | 7.13E+08 | 3.55E+08 | 824510   | 4.63E+08 | 6.14E+08 | 8.66E+08 | 3.46E+09 |
| 코스닥 지수       | 1186  | 841.1601 | 114.4289 | 428.35   | 762.185  | 847.505  | 919.4125 | 1060     |
| 코스닥 거래량      | 1186  | 1.31E+09 | 5.21E+08 | 6.2E+08  | 9.52E+08 | 1.17E+09 | 1.5E+09  | 5.07E+09 |
| WTI 유가       | 1186  | 69.53344 | 23.29195 | 7.79     | 62.09    | 73.735   | 82.03    | 126.47   |
| 금(XAU) 가격    | 1186  | 1937.514 | 263.5906 | 1471     | 1778.307 | 1870.39  | 1985.455 | 2786.19  |
| 다우존스 지수      | 1186  | 33603.14 | 4657.789 | 18591.93 | 31022.09 | 33913.62 | 35627.82 | 45014.04 |
| 다우존스 거래량     | 1186  | 3.69E+08 | 1.13E+08 | 1.17E+08 | 3.02E+08 | 3.43E+08 | 4.02E+08 | 1.22E+09 |
| S&P500 지수    | 1186  | 4250.18  | 764.0219 | 2237.4   | 3810.15  | 4200.01  | 4591.015 | 6090.27  |
| 통화량(M1)      | 1186  | 1219.395 | 103.6807 | 944.3064 | 1184.088 | 1221.11  | 1287.187 | 1371.921 |
| 통화량(M2)      | 1186  | 3616.388 | 347.3367 | 2935.64  | 3309.121 | 3718.333 | 3843.787 | 4183.535 |
| 한국 정책금리      | 1186  | 2.037789 | 1.303587 | 0.5      | 0.548387 | 1.75     | 3.5      | 3.5      |
| 미국 정책금리      | 1186  | 2.60763  | 2.31595  | 0.25     | 0.25     | 1.75     | 5.25     | 5.5      |
| 소비자물가지수(CPI) | 1186  | 2.811298 | 1.658261 | -0.2     | 1.425    | 2.7      | 3.8      | 6.3      |
| 생산자물가지수(PPI) | 1186  | 111.5014 | 7.401748 | 98.93    | 103.89   | 116.27   | 117.5    | 119.56   |

|                                |      |           |          |           |           |           |           |          |
|--------------------------------|------|-----------|----------|-----------|-----------|-----------|-----------|----------|
| 경상수지                           | 1186 | 5333.791  | 4255.906 | -4205     | 1862      | 6365      | 7438      | 13096    |
| 코스피 변동성 (KSVKOSPI)             | 1186 | 20.30508  | 6.604767 | 11.73     | 16.5625   | 18.38     | 22.415    | 69.24    |
| 달러/엔 환율                        | 1186 | 127.8556  | 18.42469 | 102.678   | 109.3763  | 130.8025  | 145.341   | 161.607  |
| 달러/위안 환율                       | 1186 | 6.867263  | 0.318528 | 6.3115    | 6.522125  | 6.94415   | 7.1455    | 7.3278   |
| 미국 10 년물 국채금리                  | 1186 | 0.267769  | 0.139671 | 0.0499    | 0.1415    | 0.2915    | 0.401     | 0.4988   |
| 구리 가격                          | 1186 | 3.820936  | 0.631159 | 2.1195    | 3.553     | 3.8995    | 4.28875   | 5.119    |
| 알루미늄 가격                        | 1186 | 2313.547  | 420.7198 | 1452      | 2126      | 2302.5    | 2534.125  | 3873     |
| VIX(주식 변동성)                    | 1186 | 21.43804  | 8.368224 | 11.86     | 15.855    | 19.63     | 25.0225   | 82.69    |
| OVX(유가 변동성)                    | 1186 | 44.72318  | 24.29387 | 23.73     | 34.28     | 39.005    | 47.485    | 325.15   |
| 이벤트 수 (events_cnt)             | 1186 | 133581.2  | 24788.61 | 0         | 117551    | 133423.5  | 150155    | 216375   |
| 이벤트 평균 톤 (events_tone_mean)    | 1186 | -1.979816 | 0.258274 | -3.333169 | -2.133663 | -1.963814 | -1.832024 | 0        |
| 한국 관련 톤 (events_tone_kor_mean) | 1186 | -0.832832 | 0.832322 | -3.924516 | -1.336452 | -0.710838 | -0.234973 | -1.06649 |
| GKG 문서 수 (gkg_doc_cnt)         | 1186 | 88501.87  | 24450.6  | 0         | 68474.75  | 85789     | 107725    | 157565   |
| 한국 관련 문서 수 (gkg_kr_loc)        | 1186 | 617.3356  | 276.5282 | 0         | 435       | 547       | 750       | 3016     |
| 직접 뉴스 평균 감정 점수                 | 1186 | -0.070743 | 0.429306 | -1        | -0.3636   | -0.07415  | 0.207875  | 1        |
| 직접 뉴스 기사 수                     | 1186 | 12.69646  | 4.440581 | 0         | 10        | 13        | 16        | 20       |
| 간접 뉴스 평균 감정 점수                 | 1186 | -0.040528 | 0.36739  | -1        | -0.1667   | 0         | 0         | 1        |
| 간접 뉴스 기사 수                     | 1186 | 3.875211  | 3.31109  | 0         | 1         | 3         | 6         | 18       |
| 전체 뉴스 평균 감정 점수                 | 1186 | -0.068784 | 0.351629 | -1        | 0.298525  | -0.0588   | 0.15      | 1        |
| 전체 뉴스 기사 수                     | 1186 | 16.57167  | 3.709767 | 0         | 15        | 18        | 19        | 20       |

본 연구의 데이터 전처리는 다음과 같은 절차를 거쳐 수행되었다. 우선, 기준 데이터

설정이다. 전체 분석의 기준이 되는 날짜(Date) 변수와 원/달러 환율의 증가 및 시가 데이터를 구축하였다. 이때 주말과 공휴일 등 비영업일은 제거하여 실제 금융시장에서의 거래일만을 반영하였다.

두 번째 단계는 일 단위 변수 병합이다. 날짜를 기준으로 유가, 금 가격, 주요 주가지수, 변동성 지표와 같은 일 단위 변수들을 순차적으로 병합하였다. 각 월 단위의 거시경제 변수(예: 정책금리, 소비자물가지수(CPI), 생산자물가지수(PPI), 경상수지, 통화량(M1, M2))는 해당 월 발표 기준으로 월간 대표값을 설정하여, 해당 월의 모든 거래일에 동일하게 반영되도록 병합하였다.

세 번째는 GDELT 이벤트 데이터 및 뉴스 감성 결합이다. GDELT에서 추출한 이벤트 데이터와 뉴스 감성 데이터를 동일한 일 단위로 맞추어 결합하였다. 이벤트 데이터에는 글로벌 및 한국 관련 이벤트 수, 평균 톤 등이 포함되며, 뉴스 감성 변수는 직/간접적으로 관련된 뉴스의 일별 평균 감성 점수 및 기사 수로 구성된다.

네 번째는 결측치 처리이다. 뉴스 감성 데이터에서만 결측치가 발생했으며, 2020-2024년 기간 동안 총 13일치의 뉴스 감성 값이 결측되었다. 해당 결측치는 분석의 일관성을 유지하기 위해 0으로 대체하였다. 다른 변수들에서는 결측치가 없었고, 별도의 보정 과정은 필요하지 않았다. 이와 같은 절차를 통해 모든 데이터는 일 단위로 정렬된 통합형 시계열 데이터프레임으로 구성하였다.

마지막은 데이터 분리 및 정규화이다. 최종 데이터는 1,186개의 관측치를 기반으로 학습(80%)과 테스트(20%) 데이터로 분할하였으며, 모든 수치형 변수는 RobustScaler로 정규화하였다. RobustScaler는 중앙값과 사분위 범위를 활용하여 극단값(outlier)의 영향을 최소화하는 장점이 있어, 다양한 범위의 데이터에 대해 더욱 효과적인 정규화 방법을 제공한다.

## 5. 분석 방법론: LSTM, GRU, CNN-LSTM, CNN-GRU

본 연구는 환율의 단기 예측력을 비교 및 평가하기 위해 순환신경망(RNN) 계열의 단일 모형(LSTM, GRU)과 합성곱-순환 하이브리드 모형(CNN-LSTM, CNN-GRU)을 병렬적으로 구축하였다. 최근 외환시장은 거시, 금융, 원자재, 이벤트, 감성 등 이질적 신호가

동시적으로 상호작용하는 복합계로서, 저차원의 선형적 상호작용을 가정하는 통계 모형만으로는 비정형적 동학을 포착하기 어렵다. 이에 따라, 장기 의존성과 국소 패턴을 동시에 학습하는 딥러닝 아키텍처가 시계열 예측의 주된 대안으로 부상하고 있다.

### 1) 단일 RNN 모형: LSTM, GRU

LSTM은 Hochreiter and Schmidhuber (1997)가 제안한 메모리 셀 구조로, 입력·망각·출력 게이트를 통해 vanishing/exploding gradient 문제를 완화하고 장기 의존성을 안정적으로 학습한다. 반면 Zheng and Chen (2021)에 따르면 GRU는 update/reset의 두 게이트로 구조를 단순화하여 매개변수 수를 절감하면서도 LSTM에 근접한 성능을 보이며, 동일한 데이터·에폭 하에서 수렴 속도와 연산 효율이 우수하다는 장점이 있다. Qu and Zhao (2019)에 의하면 외환 예측 맥락에서 LSTM은 전통 RNN 대비 RMSE와 MAE를 유의하게 낮춘다는 보고가 다수 존재하며(예: EUR/USD 사례), Agusting and De Melin (2024)에 의하면 GRU는 비선형·비정상 구간에서 패턴 전이를 민감하게 추적해 CNN 대비 우수한 결과를 보이기도 한다(ARS/USD). 또한 Islam and Hossain (2021)에 의하면 두 모형의 보완적 강점을 결합할 경우, 단일 구조 대비 예측정확도가 향상된다는 하이브리드 근거도 축적되어 왔다. 종합하면, 선행연구들은 LSTM과 GRU가 외환 시장 예측에서 높은 잠재력을 지니며, 상황에 따라 하이브리드 접근이 예측 성능 개선에 유의미하게 작동할 수 있음을 보여준다.

따라서 본 연구는 뉴스 요약 및 댓글 감정 점수와 같은 비정형 텍스트 기반 심리 변수를 포함한 시계열 데이터를 CNN-LSTM과 CNN-GRU 모델에 적용하였다. 이로써 CNN이 시장 심리의 국소적 변동을 효과적으로 포착하고, RNN 계열이 이를 시간 축에서 장기적 흐름으로 연결함으로써, 원/달러 환율 예측의 정밀도를 한층 높일 수 있을 것으로 기대된다.

본 연구는 환율의 단기 예측력을 비교 및 평가하기 위해 순환신경망(RNN) 계열의 단일 모형(LSTM, GRU)과 합성곱-순환 하이브리드 모형(CNN-LSTM, CNN-GRU)을 병렬적으로 구축하였다. 최근 외환시장은 거시, 금융, 원자재, 이벤트, 감정 등 이질적 신호가 동시적으로 상호작용하는 복합계로서, 저차원의 선형적 상호작용을 가정하는 통계 모형만으로는 비정형적 동학을 포착하기 어렵다. 이에 따라, 장기 의존성과 국소 패턴을 동시에 학습하는 딥러닝 아키텍처가 시계열 예측의 주된 대안으로 부상하고 있다.

## 2) 하이브리드 모형: CNN-LSTM, CNN-GRU

딥러닝 기반 시계열은 최근 국소 필터링(CNN)과 장기 의존 학습(RNN)을 결합하는 하이브리드로 진화하고 있다. CNN-LSTM/GRU는 1D 합성곱을 통해 시계열의 단주기 및 국소적 급등락, 스파이크, 군집 변동 등 미시 패턴을 전처리 단계에서 추출하고, 그 고수준 특징 맵을 LSTM 혹은 GRU에 전달하여 중장기 흐름을 학습한다. 이 구조는 잡음이 많은 고차원 입력에서 표현 효율성을 높이고, 장주기 신호의 단절 없는 전파를 돕는다. Lu, Li, Li, Sun, and Wang (2020)에 따르면 금융 예측에서 CNN-LSTM이 단일 구조를 능가한다는 증거가 보고되어 있으며, Jing, Wu, and Wang(2021)에 의하면 투자자 심리를 포함할 때 추가적 개선이 관찰된다.

## 3) 모형 선택의 근거와 기대효과

딥러닝 기반 시계열은 최근 국소 필터링(CNN)과 장기 의존 학습(RNN)을 결합하는 하이브리드로 진화하고 있다. CNN-LSTM/GRU는 1D 합성곱을 통해 시계열의 단주기·국소적 급등락, 스파이크, 군집 변동 등 미시 패턴을 전처리 단계에서 추출하고, 그 고수준 특징 맵을 LSTM 혹은 GRU에 전달하여 중·장기 흐름을 학습한다. 이 구조는 잡음이 많은 고차원 입력에서 표현 효율성을 높이고, 장주기 신호의 단절 없는 전파를 돕는다. Lu, Li, Li, Sun, and Wang (2020)에 따르면 금융 예측에서 CNN-LSTM이 단일 구조를 능가한다는 증거가 보고되어 있으며, Jing, Wu, and Wang(2021)에 의하면 투자자 심리를 포함할 때 추가적 개선이 관찰된다.

LSTM/GRU는 금리와 물가 등 저주파 구조 신호의 누적 효과를, CNN은 VIX/OVX 급등, 이벤트 카운트 급증, 감정 급변 등 고주파 충격을 요약한다. 결합 시 다중 주기성(Multi-horizon Dynamics)을 공식적으로 반영한다. 또한, 원자재와 리스크 지표의 우측 장꼬리와 이벤트와 감정의 이질적 스케일은 합성곱, 풀링, 배치정규화로 1차 완충되고, RNN의 게이트로 2차 선별된다. 그리고 GRU 기반 하이브리드는 매개변수가 상대적으로 적어 적은 예폭에서도 수렴이 빠르며, 과적합 위험에 더 강건하다.

## 6. 예측 성능평가 지표

본 연구에서는 원/달러 환율 예측 모델의 성능을 다각적 관점에서 평가하기 위해, 총 여섯 가지 회귀 지표를 활용하였다: RMSE (Root Mean Squared Error), MSPE (Mean Squared Percentage Error), MAE (Mean Absolute Error), MAPE (Mean Absolute Percentage Error), MedAE (Median Absolute Error), MedAPE (Median Absolute Percentage Error). 이들 지표는 예측 모델이 제공하는 성능을 정확도, 강건성(robustness), 그리고 이상치에 대한 민감도까지 종합적으로 평가할 수 있게 해준다.

RMSE는 예측 오차의 제곱을 평균한 후 그 제곱근을 취한 값으로, 오차의 크기를 더 강하게 반영하는 특징이 있다. 예측 값과 실제 값의 차이가 클수록 제곱이 되어 RMSE 값이 더 크게 증가하므로, 모델의 오차 제어 능력을 평가하는 데 매우 유용하다. RMSE는 데이터의 단위를 그대로 유지하므로 해석이 직관적이고, 모델의 예측 성능을 정량적으로 평가하는 데 널리 사용된다. 특히 큰 오차가 중요한 예측 상황에서는 매우 중요한 지표로, 예측 정확도를 극대화하는 모델을 찾는 데 도움을 준다.

MSPE는 예측 오차를 실제값으로 정규화한 후 제곱하여 평균한 값이다. 이는 상대적 오차 크기에 주목하여 예측의 정확도를 평가하며, 모델이 예측 오차의 상대적 크기에 얼마나 민감한지를 평가할 수 있다. MSPE는 예측 오차가 모델의 편향(bias)과 분산(variance)을 동시에 반영하기 때문에, 모델의 정확성뿐만 아니라 분포의 불균형에도 민감하게 반응할 수 있다. 또한, 상대적인 오차를 강조하여, 편향이나 고른 분산을 평가하는 데 중요한 역할을 한다.

MAE는 예측값과 실제값 간의 절대적 차이를 평균한 값으로, 각 오차를 동일한 가중치로 반영하여 평균적인 예측 정확도를 평가하는 데 유용하다. RMSE와 비교할 때, 이상치에 대한 민감도가 적어 이상치가 존재하는 데이터에서 모델의 성능을 안정적으로 평가할 수 있다. MAE는 직관적으로 이해할 수 있는 지표로, 예측이 잘 맞았는지 아닌지를 빠르게 파악하는 데 유용하다. 또한, 오차 크기에 대해 균등한 평가를 제공하여, 모델의 일관된 예측 정확도를 확인하는 데 적합하다.

MAPE는 절대 오차를 실제값으로 나눈 뒤 백분율로 환산한 값이다. 이를 통해 모델의 오차를 직관적으로 이해할 수 있으며, 비율 오차를 기반으로 예측 성능을 평가할 수 있다. 그러나 실제값이 0이거나 매우 작은 경우에는 무한대의 값이 발생할 수 있어 이 지표의

사용에 주의가 필요하다. 이런 문제로 인해 일부 연구에서는 MAPE의 대안 지표를 제시하기도 한다. 그럼에도 불구하고, MAPE는 예측이 잘 이루어졌는지 빠르게 파악할 수 있는 유용한 지표로 여전히 많은 경우에 사용된다.

MedAE는 절대 오차의 중앙값을 사용하여 이상치에 대한 영향을 최소화한 지표이다. 평균(Mean)이 아닌 중앙값(Median)을 사용함으로써, 데이터 분포의 왜곡에 덜 민감하며 모델이 일관되게 성능을 발휘하는지 평가할 수 있다. MedAE는 이상치(outlier)가 존재하는 경우에도 모델의 예측 성능을 더 안정적으로 평가할 수 있기 때문에, 특히 비정상적인 분포나 급격한 변동이 있는 데이터셋에서 유용하게 활용될 수 있다.

MedAPE는 절대 백분율 오차의 중앙값을 사용하여 MAPE의 직관성을 유지하면서도 극단적인 오차의 영향을 완화하는 지표이다. MAPE와 유사하게 백분율 기준으로 예측 성능을 평가하지만, 중앙값(Median)을 사용하여 이상치에 강건한 특성을 가짐으로써, 금융 시계열과 같이 이상치가 자주 발생하는 데이터셋에서 더 안정적이고 정확한 평가가 가능하다.

이처럼 다양한 예측 성능 지표를 함께 활용함으로써, 본 연구는 모델의 평균적 예측 정확도뿐만 아니라 이상치에 대한 강건성(robustness)과 실제 금융 예측 환경에서의 해석 가능성을 종합적으로 검증하였다. 여러 지표를 활용하는 것은 각 지표가 모델의 다른 성능 측면을 강조하기 때문이다. 예를 들어, RMSE는 일관된 환율예측의 정확성을, MSPE는 높은 변동성에도 정확한 예측을, MAE와 MAPE는 전반적인 정확도 이해를 강조한다. 또한, MedAE와 MedAPE는 이상치가 많은 비정상적인 환율 변동에도 강건하고 안정적인 예측을 확인하는 데 중요한 역할을 한다. 따라서, 이들 지표를 종합적으로 고려하여 본 연구에서는 모델 성능의 균형을 잡고, 여러 가지 측면에서의 평가를 통해 예측 모델이 금융 시장에서의 실제 예측 환경에 적합한지를 다각도로 검토하였다.



## IV. 연구결과

### 1. 실험과정: 변수조합과 모델, 그리고 하이퍼파라미터

본 연구는 원/달러 환율의 다음 영업일 증가(1-step ahead) 예측을 목표로, LSTM, GRU, CNN-LSTM, CNN-GRU의 네 가지 딥러닝 아키텍처를 동일한 실험 설계 하에 비교하였다. 전체 표본은 시계열 순서를 보존한 상태로 학습 80% / 테스트 20%로 분할하였으며, 시간의 전진 정보 누설을 차단하기 위해 모든 전처리와 모형 적합은 학습 세트 기준으로 학습된 매개변수만을 사용하여 테스트 세트에 적용하였다. 예측력의 과거 정보 활용 범위를 점검하기 위해 입력 시퀀스 길이(lookback window)를 5, 10, 20, 30, 60, 90일로 변화시키며, 단/중/장기 메모리 길이 변화가 성능에 미치는 영향을 체계적으로 분석하였다.

모형의 추정 불확실성과 초기화 민감도를 완화하기 위해, 각 윈도우와 입력변수 조합마다 난수 시드 42, 55, 68을 적용해 3회 반복 학습을 수행하였고, 보고치는 이들의 산술평균으로 제시하였다. 입력 특성은 모든 실험에서 RobustScaler로 정규화하였다. 본 스케일러는 중앙값과 사분위 범위를 사용하여 극단값(outlier)에 대한 민감도를 낮추므로, 고변동과 장꼬리 분포를 보이는 금융 시계열의 스케일 불안정성을 완충하는 데 적합하다.

입력 변수는 다음의 네 가지 케이스로 구성하여 구조적 요인과 사건 및 심리 요인의 한계 기여를 분리 확인하였다. (1) Baseline: 전통적인 거시 및 시장 변수만을 포함하여 예측, (2) Baseline+이벤트 데이터: Baseline에 GDELT 이벤트 변수를 포함하여 예측, (3) Baseline+감성 데이터: Baseline에 뉴스 요약 정보와 직접/간접/전체 감정 변수 포함하여 예측, (4) Baseline에 이벤트와 감성 데이터를 모두 반영하여 예측한 조합이다.

모형 아키텍처는 다음과 같이 동일한 설계 원칙을 유지하였다. LSTM/GRU는 각각  $64 \rightarrow 32$  유닛의 2층 순환 스택으로 구성하고, 층 사이에 Dropout=0.1을 적용하여 과적합을 억제하였다. CNN-LSTM/CNN-GRU는 입력 시계열에 1D 합성곱(Conv1D, kernel\_size=3, causal padding, ReLU)을 적용해 국소적인 급등락이나 스파이크와 같은 패턴을 추출한 뒤, Batch Normalization과 Dropout을 거쳐 각각 LSTM( $64 \rightarrow 32$ ) 또는 GRU( $64 \rightarrow 32$ ) 블록으로 중장기 의존성을 학습하도록 구성하였다. 모든 모형의 출력층은 Dense(1)이며, 손실함수는 MSE로

고정하였다. 최적화, 배치 크기, 에폭, 조기 종료 등 세부 학습 하이퍼파라미터는 <표 4>에 요약하였다.

<표 4> 딥러닝 아키텍처 별 세부 하이퍼파라미터

| 알고리즘     | 주요 파라미터             | 값                  |
|----------|---------------------|--------------------|
| LSTM     | Unit Numbers        | 64 → 32 (2-스택)     |
|          | Dropout Ratio       | 0.1                |
|          | Dense Units         | 1                  |
| GRU      | Unit Numbers        | 64 → 32 (2-스택)     |
|          | Dropout Ratio       | 0.1                |
|          | Dense Units         | 1                  |
| CNN-LSTM | Filters             | 32                 |
|          | Kernel Size         | 3 (causal padding) |
|          | Activation          | ReLU               |
|          | Batch Normalization | 적용                 |
|          | LSTM Units          | 64 → 32            |
|          | Dropout Ratio       | 0.1                |
|          | Dense Units         | 1                  |
| CNN-GRU  | Filters             | 32                 |
|          | Kernel Size         | 3 (causal padding) |
|          | Activation          | ReLU               |
|          | Batch Normalization | 적용                 |
|          | GRU Units           | 64 → 32            |
|          | Dropout Ratio       | 0.1                |
|          | Dense Units         | 1                  |

본 연구는 모델 성능의 평균 정확도, 상대 오차, 강건성의 세 축을 동시에 점검하기 위해 RMSE, MSPE, MAE, MAPE, MedAE, MedAPE의 여섯 가지의 평가지표를 사용하였다. MSE, RMSE, MAE, MedAE는 원 단위로, MAPE, MSPE, MedAPE는 백분율 단위로 산출되었다. 또한 모든 결과는 테스트 구간 전체에 대한 지표를 기본으로 보고하고, 윈도우 길이 및 입력 변수 케이스별로 상대적 우위 패턴을 비교하였다. 이와 같은 통일된 실험은 데이터 분할 일관성, 입력 스케일 처리의 재현성, 초기화 불확실성의 평균화라는 세 측면에서 공정한 모형 간 비교 가능성을 확보한다.

요약하면, (모형) LSTM과 GRU 단일 구조와 하이브리드 구조, (메모리 길이) 5~90일 lookback, (입력 집합) 구조적 요인과 사건 및 심리 요인의 단계적 추가, (평가축) 절대,

상대 오차 및 강건성 등 네 축을 직교적으로 결합함으로써, 환율 예측에서 심리와 이벤트 변수의 한계 기여와 하이브리드 구조의 효용을 동시에 검증하도록 설계되었다.

## 2. 실험 결과1: 환율 예측의 시계열 구조의 동태적 변화

단기(5일) 구간에서는 합성곱-순환 하이브리드 구조(CNN-LSTM, CNN-GRU)가 순수 순환 신경망(LSTM, GRU)보다 전반적으로 우수한 예측 성능을 보였다. Radar chart의 면적 및 순위에 따르면, CNN-LSTM(Macro + Sentiment(Direct+Indirect)) 조합이 여섯 개의 평가 지표(RMSE, MSPE, MAE, MAPE, MedAE, MedAPE) 중 다수를 선도하며, 단기 환율 변동을 가장 안정적이고 정확하게 포착한 모델로 확인되었다.


Radar chart는 각 지표를 0~1 구간으로 정규화하여, 값이 1에 가까울수록 성능이 우수함을 의미한다. 또한 legend는 전체 면적을 기준으로 내림차순 정렬되어 있으며, 가장 상단에 위치한 조합일수록 통합 성능이 우수함을 의미한다. 해당 시각화에서 CNN-LSTM(Macro + Sentiment(Direct+Indirect))은 외곽부(1 근처)에 가장 근접하며, 6개 지표 중 4개 항목에서 최고 성능(최소 오차)을 기록하였다. 이는 직접 감성(direct sentiment)과 간접 감성(indirect sentiment)을 동시에 결합함으로써, 단기 환율 변동의 방향성과 강도를 복합적으로 반영한 결과로 해석된다. 즉, 단기 구간에서는 이벤트의 발생 자체보다 감성 톤의 변화율(감정의 상승 및 하강)이 시장 반응을 더 민감하게 설명하는 신호로 작용했음을 시사한다.

한편, CNN-GRU(Macro + Event) 조합은 중앙값 기반 강건성 지표(MedAE, MedAPE)에서 최상위권을 차지하며, 단기 충격 및 꼬리 위험 구간(tail risk)에서도 안정적 예측을 유지했다. 이는 Conv1D가 단기적 급등락 패턴을 사전 요약하여 GRU의 게이트 구조가 보다 효율적으로 시간 의존 관계를 학습하게 했기 때문이다. 반면, 순수 LSTM과 GRU 모델은 radar chart의 중심부에 위치하여 전반적으로 낮은 성능을 보였으며, 특히 변동성이 높은 단기 창구에서는 합성곱 블록이 결여된 구조의 한계가 뚜렷했다.


단기(10일) 구간에서는 5일과 달리, 모델 구조와 입력 변수 간의 상호작용 효과가 다층적으로 나타났다. Radar chart에 따르면, CNN-GRU(Macro + Event + Sentiment(Direct)), CNN-GRU(Macro + Event), 그리고 LSTM(Macro + Sentiment(Direct))의 세 조합이 6개의

검증지표 중 2개씩 1위를 차지하며 공동 1위를 형성하며 목적에 따라 균형 잡힌 성능을 보였다. 특히, CNN-GRU(Macro + Event + Sentiment(Direct))는 MAE 및 MAPE 측면에서, CNN-GRU(Macro + Event)는 MedAE 및 MedAPE 기준에서 각각 우위를 보였다. 이는 5일에서 감성 중심 신호가 지배적이었던 반면, 10일 창구에서는 이벤트와 감성의 복합적 결합이 모델 성능을 향상시킨다는 구조적 전환을 의미한다. 아마도 Conv1D를 통한 지역 패턴 요약과 GRU의 장기 메모리 구조가 10일 단위 변동에 대해 효과적으로 대응하고 있음을 보여준다. 이는 lookback 기간이 확장될수록 단기 급등락보다 중기 추세적 신호가 강화되고, 이 과정에서 GRU의 내부 게이트가 저주파 패턴을 안정적으로 학습했기 때문으로 해석된다. GRU의 간결한 구조가 이러한 패턴을 과도한 파라미터 학습 없이 안정적으로 흡수했음을 의미한다. 또한 5일 구간에서 단일 감성 중심 모델이 독보적이었던 것과 달리, 10일 구간에서는 감성과 이벤트의 상호작용이 성능 우위를 분산시키는 방향으로 작용했음을 보여준다. 즉, 5일에는 시장의 정서적 반응(sentiment response)이 지배적이었다면, 중기에는 사건과 감성 복합효과(event-sentiment synergy)가 더 적합한 설명 변수로 작동한다.

요약하면, Radar chart 분석 결과, 단기(5일)에서는 감성 융합이, 단기(10일)에서는 감성-이벤트 복합 신호가 각각 예측 성능을 극대화하였다. Lookback 10일 환경에서는 CNN-GRU 기반 복합 입력 모델이 전반적으로 최적 조합으로 평가되며, 감성 신호의 지속적 효과와 이벤트 신호의 비선형 충격이 공존하는 중기적 환율 예측 구조를 시각적으로 확인할 수 있다. 이 결과는 합성곱-순환 하이브리드의 구조적 장점이 lookback이 증가함에도 유지되며, 입력 변수 간 결합 전략에 따라 성능 패턴이 유연하게 변동함을 시사한다. 즉, 시간 창구가 짧을수록 시장의 정서적 톤 변화가 직접적 예측력으로 작용하고, 기간이 길어질수록 사건 발생의 누적 효과가 점차 가중되는 양상이 뚜렷하다. 이러한 결과는 텍스트 기반 감성 신호가 전통적 거시 및 금융 변수보다 즉시적이고 민감한 예측 신호로서 환율 단기 변동을 설명할 수 있음을 실증적으로 보여준다.



<단기 예측에서의 감성 융합형 모델의 성능>



<단기-중기 전환에서의 이벤트와 감성 복합 효과의 확대>

[그림 2] 단기 데이터 학습을 통한 환율 예측 종합 성능 Radar Chart

중기 예측 구간(lookback 20일)에서는 CNN-GRU(Macro + Event + Sentiment(Direct)) 조합이 여섯 가지 평가 지표(RMSE, MSPE, MAE, MAPE, MedAE, MedAPE) 중 다수에서 최고 성능을 기록하며, 가장 우수한 통합 예측력을 보인 모델로 나타났다. 아울러 Radar chart의 면적 및 순위 또한 이를 일관되게 지지하며, CNN-GRU 기반의 이벤트와 감성 결합형 모델이 중기 구간에서 최적의 구조적 효율성을 확보했음을 시사한다. 이는 이벤트(Event) 정보가


감성(Sentiment)과 결합할 때 중기적 환율 변동의 비선형 패턴을 포착하는 데 효과적임을 보여준다. 특히 Conv1D 기반의 CNN 전처리가 사건 발생 시점의 단기 충격을 정규화하고, GRU의 간결한 게이트 구조가 중기적 시간 의존성을 효율적으로 추적하면서, 감성 톤의 방향성(directional sentiment)이 이를 보완적으로 강화하는 구조적 시너지가 형성된 것으로 해석된다.

한편, CNN-GRU(Macro + Event) 조합도 radar chart에서 두 번째로 넓은 면적을 차지하며 안정적 성능을 보였다. 이는 감성 정보가 없더라도 사건의 빈도와 중요도가 일정 기간 동안 누적되며 환율에 중기적 영향을 미친다는 점을 시사하는 실증적 결과이다


중기 구간(lookback 30일)에서는 LSTM(Macro + Event) 모델이 전 지표 기준에서 가장 넓은 radar 영역을 형성하며, 30일 변동에 대해 최적의 예측 성능을 달성한 모델로 확인되었다. Radar chart의 외곽 패턴에 따르면, LSTM(Macro + Event)은 RMSE, MSPE, MAE, MAPE 등 주요 절대오차 지표에서 1위를 차지하였으며, 이는 단기 구간에서 하이브리드 모델(CNN-LSTM, CNN-GRU)이 주도했던 패턴과 뚜렷하게 대조된다. 이러한 결과는 합성곱 전처리의 효과가 단기 변동(high-frequency noise)에 한정되는 반면, 30일 단위의 신호에서는 순수 순환 구조의 게이트 메커니즘이 장기적 패턴 유지에 더 효과적임을 보여준다. 즉, CNN 기반 지역 특징 요약이 중기 구간에서는 정보 손실을 유발할 가능성이 있으며, 반면 LSTM의 메모리 셀은 이벤트 발생 시점 이후 수 주간 지속되는 시장 반응을 비선형적으로 누적 학습할 수 있음을 의미한다. 특히 Macro + Event 조합이 Macro + Sentiment 조합보다 radar 면적이 넓게 나타난 것은, 중기 구간에서는 감성 신호보다 정책금리, 무역지수, 원자재가격 등 거시·금융 변수와 글로벌 사건 발생량이 더 강한 설명력을 가지는 구조적 전환을 반영한다. 이 시점에서 감성 톤의 변동은 단기적 시장 심리에 국한되며, 중기 환율 추세에는 사건(event) 정보가 누적적으로 작용함을 radar chart가 시각적으로 입증하고 있다.

Radar chart 결과를 종합하면, lookback 5일에서는 감성 중심 모델(CNN-LSTM, Sentiment 융합형)이 최적, lookback 10~20일에서는 이벤트 및 감성 복합형(CNN-GRU)이 최적, 그리고 30일에서는 사건 중심의 순수 LSTM(Macro + Event)이 최적 구조로 전환되는 패턴이 명확히 관찰되었다. 이러한 변화는 시간 창구의 확장에 따라 지배적 예측 요인이 감성 → 복합 → 사건 순으로 이동하는 동태적 구조 전환(dynamic structural shift)을 의미한다. 즉,

단기에는 시장 정서(sentiment)가 빠르게 반응하는 고주파 신호로 작용하지만, 장기로 갈수록 복합적인 사건(event)의 누적적 영향이 시장의 방향성을 결정짓는 저주파 신호로 작용한다. 이는 텍스트 기반 감성 정보가 단기 예측의 효율적 보조 변수로서 작용하되, lookback 기간이 늘어날수록 거시경제적 충격 변수의 상대적 중요도가 강화된다는 시계열-텍스트 융합 모델의 구조적 한계와 확장성을 동시에 보여주는 결과이다.



<중기 예측에서의 CNN-GRU 하이브리드의 통합 성능>



<중기-장기 전환에서의 순수 LSTM 기반 구조로의 회귀 성능>

[그림 3] 중기 데이터 학습을 통한 환율 예측 종합 성능 Radar Chart

장기 예측 구간(lookback 60일)에서는 LSTM(Macro + Event + Sentiment(All)) 조합이 여섯 가지 검증 지표(RMSE, MSPE, MAE, MAPE, MedAE, MedAPE) 중 4개에서 1위를 차지하며, 가장 우수한 종합 예측 성능을 보인 모델로 나타났다. Radar chart의 전체 면적과 순위 모두 이 결과를 일관되게 뒷받침하며, 이는 장기 시계열 구간에서 순수 LSTM 구조가 합성곱-순환 하이브리드(CNN-LSTM, CNN-GRU)를 능가하는 구조적 전환점이 발생했음을 보여준다. 이는 감성(sentiment)과 이벤트(event) 신호가 결합될 때, 단기 노이즈보다 장기적 추세 변동을 설명하는 누적 신호(cumulative signal)로서 기능함을 의미한다. 특히, LSTM의 장기 메모리 셀 구조가 lookback 기간이 길어질수록 누적적 상관관계를 안정적으로 유지할 수 있어, 복합 입력 변수의 시간 지연 효과를 효율적으로 통합 학습한 것으로 해석된다.

LSTM(Macro + Event) 조합 또한 radar chart에서 두 번째로 넓은 면적을 형성하며 유사한 예측력을 보였다. 이는 감성 신호를 배제하더라도 거시 및 금융 지표와 사건 변수의 장기 누적 효과가 환율의 구조적 변동성을 충분히 설명할 수 있음을 시사한다. 반면 CNN 기반 하이브리드 모델은 radar의 중심부에 위치하며, 단기에서 유효했던 합성곱 전처리의 효과가 장기 구간에서는 감소함을 확인할 수 있다. 즉, Conv1D를 통한 국소 패턴 요약은 단기 급등락 탐지에는 효과적이거나, 60일 이상의 저주파(long-horizon) 구간에서는 오히려 시점 간 의존 정보를 손실시키는 요인으로 작용한다.


초장기 예측 구간(lookback 90일)에서는 LSTM 계열이 절대적 우위를 보이며, LSTM(Macro + Event)와 LSTM(Macro + Event + Sentiment(All))이 공동 1위로 나타났다. 이 결과는 90일 수준의 예측 창에서는 감성 신호보다 거시 및 금융 변수 및 사건(Event)의 누적적 효과가 주도적 요인으로 작용함을 시각적으로 입증한다.

특히 LSTM(Macro + Event)은 MedAE, MedAPE 지표에서 최고 성능을 보였으며, LSTM(Macro + Event + Sentiment(All))은 RMSE 및 MSPE 지표에서 우위를 보였다. 이는 감성 신호가 장기 구간에서 추가적인 설명력보다는 예측 분포의 안정화(stabilization)에 기여하는 보조 변수로 작용함을 시사한다. 한편, CNN-GRU(Macro + Event + Sentiment(Direct))와 CNN-GRU(Macro Only) 조합은 radar chart의 중심부에 위치하며, 단기 구간에서 관찰되던 하이브리드 구조의 우월성이 장기에서는 완전히 소멸되는 경향을 보였다. 이는 합성곱 기반의 단기 패턴 인코딩이 장기 메모리 보존과 충돌할 수 있으며, 장기 예측에서는 오히려

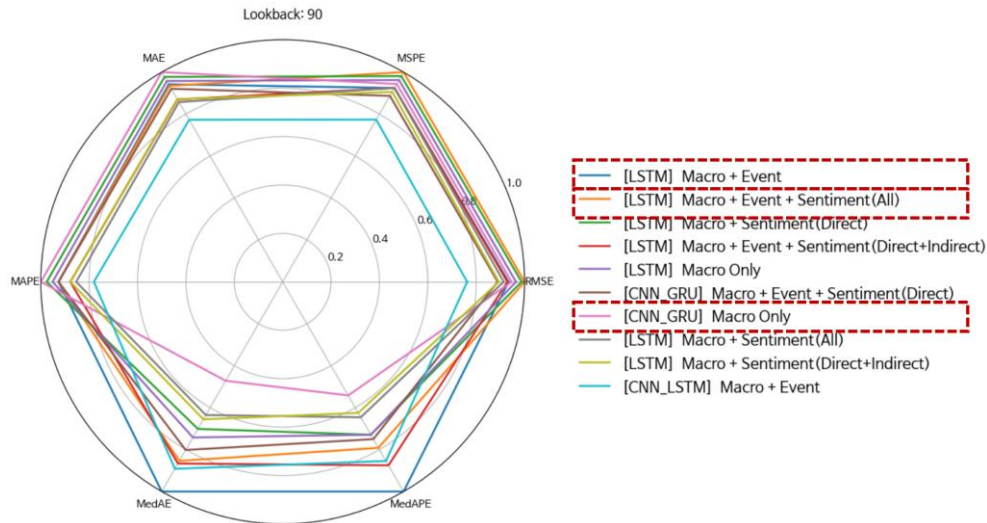


LSTM의 순차적 게이트 메커니즘이 안정적 추세를 학습하는 데 더 효과적임을 뒷받침한다. 이는 lookback이 90일 이상으로 확장될수록 감성 정보의 단기적 영향력이 약화되고, 사건 기반의 누적 충격이 예측 정확도의 주된 결정 요인으로 이동함을 명확히 보여준다.

Radar chart 결과를 종합하면, 중기(20~30일)까지는 이벤트-감성 복합 신호가 우수했으나, 장기(60~90일) 구간에서는 순수 LSTM 기반 구조가 우세로 전환되었다. 즉, 시간 창구가 길어질수록 예측 모델의 최적 구조가 CNN 기반 하이브리드에서 순수 순환형으로 이동하는 구조적 전이(structural transition)가 관찰된다. 이러한 변화는 단기 급등락(high-frequency shock)을 설명하던 감성 중심 신호가 장기 구간에서는 점차 소멸하고, 대신 거시경제나 정책 변수 및 글로벌 사건의 누적적 영향이 환율의 장기 추세를 지배함을 시사한다. 따라서 감성 정보는 장기 구간에서 필수 변수라기보다는 예측 안정성을 보조하는 정성적 요소로 기능하며, 모델 구조 측면에서는 LSTM의 장기 메모리 셀이 CNN 기반의 국소 추출보다 효율적인 장기 패턴 학습을 수행함이 실증적으로 확인되었다.



<장기 예측에서의 LSTM 기반 누적 신호의 강화 효과>



<초장기 예측에서의 사건 기반 누적 효과의 지배 성능>

[그림 4] 장기 데이터 학습을 통한 환율 예측 종합 성능 Radar Chart

### 3. 실험 결과2: 환율 예측 목적에 따른 최적 모델과 시장 신호의 지배변수 조합의 구조적 전이

본 연구에서는 예측 목적별로 세 가지 평가 관점을 설정하고, 각 관점에서 최적의 모델과 입력 변수 조합을 식별하였다. 첫째, 고변동 시장 국면에서의 일관된 예측 정확성이 필요한 경우, 둘째, 전반적 환율예측 정확성이 필요한 경우, 그리고 마지막으로 비정상적 변동에서도 예측의 강건성 확보가 중요한 경우이다. 각각의 목적은 두 개의 대표 지표로 평가되었으며, 첫 번째 범주는 RMSE와 MSPE, 두 번째는 MAE와 MAPE, 세 번째는 MedAE와 MedAPE를 사용하였다.

고변동성 구간에서도 일관된 환율 예측력 확보를 위해 RMSE와 MSPE를 기준으로 평가한 결과, LSTM(Macro + Event) 조합이 가장 우수한 성능을 보였다(RMSE=6.946, MSPE=0.259). 이 모델은 20일의 lookback 구간에서 최적값을 기록하였으며, CNN-LSTM(Macro + Event + Sentiment(All))과 LSTM(Macro + Event + Sentiment(Direct))이 각각 근접한 성능을 나타냈다. 이러한 결과는 단기 충격이 빈번히 발생하는 국면에서 이벤트 정보(event variables)가 환율의 급격한 반응과 회귀 과정을 설명하는 핵심 신호로 작용했음을 보여준다. 단기적 급등락에 대한 시장 반응을 정규화하는 동시에, LSTM의 게이트 구조가

시점 간 누적 신호를 안정적으로 학습했음을 보여준다. 즉, CNN 기반의 합성곱 전처리(Conv1D)는 국소적 패턴 감지에는 유용하지만, 20일 수준의 중단기 예측에서는 추가적 성능 향상이 제한적이었다. 반면, 단순하고 해석 가능한 Macro + Event 조합이 변동성 하의 환율 예측에서 과적합의 위험 없이 가장 일관된 예측력과 강한 설명력을 갖는다는 점을 시사한다.

평균적 예측 정확성을 나타내는 MAE와 MAPE 기준에서는, CNN-GRU(Macro + Event + Sentiment(Direct)) 조합이 가장 우수한 결과를 기록하였다(MAE=5.357, MAPE=0.392). 이는 20일 구간에서 CNN-GRU 구조가 Conv1D의 지역 패턴 요약(local summarization)을 통해 변동성을 축소시키고, GRU의 간결한 게이트 구조가 주요 추세를 효율적으로 포착했기 때문으로 해석된다. 특히 직접 감성 변수의 추가가 모델의 비선형 반응성을 높여, 가선 발생 직후의 시장 정서 변화를 효과적으로 반영한 것으로 보인다. 감성 신호가 단독으로는 불안정할 수 있으나, 이벤트 정보와 결합될 경우 시장 참여자의 기대와 반응을 보완적으로 포착할 수 있음을 보여준다. 즉, 감성 톤의 방향성이 환율의 단기적 모멘텀을 설명하는 효과적인 보조 변수로 작용했음을 시사한다. 또한 LSTM(Macro + Event, lookback=30) 역시 거의 동일한 수준의 성능을 보여, 장기 메모리 구조가 중기 예측에서도 누적된 시간 의존성을 안정적으로 유지할 수 있음을 입증한다. 즉, CNN-GRU 구조는 단기·중기 구간에서 감성과 사건의 결합 효과를 극대화하여 평균 오차를 최소화하는 데 유리하며, LSTM은 상대적으로 더 긴 시간축에서의 안정적 추세 학습에 유효한 형태로 구분된다.

비정상적 환율 변동에서의 중앙값 기반 강건성(MedAE, MedAPE)을 평가한 결과, LSTM(Macro + Event + Sentiment(Direct)) 조합이 가장 뛰어난 예측 안정성을 보였다(MedAE=4.317, lookback=30). 이는 감성 신호가 비선형적 충격이 발생하는 시점에서 LSTM의 장기 메모리와 상호 보완적으로 작용하여, 오차 분포의 꼬리(Tail) 영역을 효과적으로 억제하는데 도움을 준 것으로 보인다. 에서 최저값을 기록하며 가장 안정적인 예측력을 보였다. 반면, 장기 예측 구간(lookback=90)에서는 LSTM(Macro + Event) 조합이 MedAPE=0.316으로 최저치를 기록하며, 감성 신호를 제외한 간결한 피처 구성이 오히려 장기적 분포 안정성에 유리하였다. 이러한 패턴은 감성 신호가 중기 구간에서의 강건성 향상에 기여하지만, 장기 구간에서는 그 효과가 점차 희석되고 오히려 거시 및 사건 정보(Macro-Event)의 누적 효과가 지배적으로 작용함을 시사한다. 즉, 감성 신호는 단기와 중기 예측에서 비선형적 변동성을 흡수하는 완충 변수로 작용하지만, 장기 예측에서는

감성의 영향력이 점차 약화되고 사건 기반의 누적 효과가 지배적인 예측 요인으로 전환된다.

아울러, 예측 목적별 최적 조합들을 비교한 결과 공통적으로 다음 세 가지의 특징이 도출되었다. 첫째, 모든 최적 조합이 Macro 변수와 Event 변수를 기본적으로 포함한다. 이는 환율 예측에서 거시적 요인과 사건의 결합이 텍스트 감성 변수보다 항상 상위 수준의 설명력을 갖는다는 점을 실증적으로 확인한 결과이다. 거시지표는 구조적 안정성을, 사건지표는 단기 충격의 방향성을 제공함으로써, 두 변수군이 상호보완적 기능을 수행한다. 둘째, 직접 감성 변수는 특히 중기에서의 성능 개선을 유의하게 유도하였다. 이는 감성 정보가 단기 시장 반응보다는 일정 기간 누적된 정서 변동의 신호로 작용할 때 더 높은 신뢰도를 갖는다는 점을 의미한다. 즉, 감성 변수는 고빈도 시점에서 노이즈를 유발하기 쉬우나, 일정 길이의 lookback에서는 정서적 방향성의 추세적 전환을 포착할 때 모델의 예측력을 강화할 수 있다. 셋째, 변수 선별 없이 과도한 모든 변수들의 결합은 성능 향상보다 오히려 미세한 저하를 초래하는 경향을 보였다. 이는 다중공선성(multicollinearity)과 정보 중복으로 인해 모델의 일반화 성능이 저해된 결과로, 환율 예측에 있어서는 변수의 양보다 시장의 신호를 잘 반영할 수 있는 질이 더 중요함을 보여준다. 따라서 실증 결과는 “Macro + Event” 또는 “Macro + Event + Sentiment(Direct)”와 같은 최적 변수 구성이 고변동성, 평균 정확도, 강건성의 모든 목적에서 일관되게 상위권을 유지함을 입증하였다.

종합하면, 본 연구의 실험 결과는 시간 창구와 예측 목적에 따라 지배적인 신호 구조가 동적으로 전이됨을 보여준다. 고변동 환경에서는 LSTM(Macro + Event)가 가장 일관된 성능을 보였고, 평균적 정확도 기준에서는 CNN-GRU(Macro + Event + Sentiment(Direct)), 비정상적 변동 구간에서는 LSTM(Macro + Event + Sentiment(Direct)) 또는 LSTM(Macro + Event)이 각각 최적 조합으로 확인되었다. 5~10일 단기 구간에서는 감성 중심 모델이, 20~30일 중기 구간에서는 감성과 이벤트의 복합 신호가, 60~90일 장기 구간에서는 사건 중심 모델이 각각 최적 구조로 전환되었다. 즉, 감성 → 복합 → 사건 중심으로 이동하는 구조적 예측 패턴이 확인되었다. 특히 중기(20~30일) 구간에서 감성과 이벤트의 복합 신호가 비선형 변동을 설명하는 데 효과적이었으며, 장기(60~90일) 구간에서는 LSTM의 장기 메모리 셀이 사건 기반 누적 충격을 안정적으로 흡수하며 구조적 우위를 확보하였다. 이러한 동태적 전이는 딥러닝 기반 환율 예측에서 입력 변수의 시계열적 성격과 상호작용 구조를 동적으로 고려해야 함을 시사한다. 결과적으로, Macro와 Event 변수는 모든

구간에서 필수적 기반, Sentiment(Direct)는 중기적 비선형 반응 보완 요인, 그리고 간결한 피쳐 구성이 과적합 없이 안정적 예측을 보장하는 핵심 설계 원칙으로 정리된다. 따라서 본 연구의 결과는 딥러닝 기반 환율 예측에서 시간 창구별 모델과 변수 설계가 필요함을 시사하며, 감성 정보는 단기 시장 반응을, 이벤트 정보는 장기 추세 변동을 설명하는 상호보완적 역할을 수행함을 보여준다.

**<표 5> 시장의 환율 예측 및 대응 목적에 따른 최적 예측 모델과 변수조합 결과**

| Prediction Purpose                                     | Metric 1     | Metric 2     | Model Ranking  | Feature Case                             | Best Lookback |
|--|--------------|--------------|----------------|--|---------------|
| 높은 변동성에도 일관된 환율예측 정확성<br>(Metric1=RMSE, Metric2=MSPE)  | <u>6.946</u> | <u>0.259</u> | <u>LSTM</u>    | <u>Macro + Event</u>                     | <u>20</u>     |
|  | 6.976        | 0.261        | CNN_LSTM       | Macro + Event + Sentiment(All)           | 20            |
|  | 6.995        | 0.262        | LSTM           | Macro + Event + Sentiment(Direct)        | 20            |
|  | 6.996        | 0.263        | CNN_GRU        | Macro + Event                            | 20            |
|  | 7.000        | 0.262        | GRU            | Macro Only                               | 20            |
| 전반적 환율예측 정확성<br>(Metric1=MAE, Metric2=MAPE)            | <u>5.357</u> | <u>0.392</u> | <u>CNN_GRU</u> | <u>Macro + Event + Sentiment(Direct)</u> | <u>20</u>     |
|  | 5.363        | <u>0.392</u> | <u>LSTM</u>    | <u>Macro + Event</u>                     | <u>30</u>     |
|  | 5.364        | 0.393        | CNN_GRU        | Macro + Event + Sentiment(Direct)        | 10            |
|  | 5.378        | 0.393        | CNN_GRU        | Macro + Event + Sentiment(Direct)        | 30            |
|  | 5.383        | 0.394        | CNN_GRU        | Macro + Event                            | 20            |
| 비정상적 환율변동에 안정적 예측성능<br>(Metric1=MedAE, Metric2=MedAPE) | <u>4.317</u> | 0.317        | <u>LSTM</u>    | <u>Macro + Event + Sentiment(Direct)</u> | <u>30</u>     |
|  | 4.358        | <u>0.316</u> | <u>LSTM</u>    | <u>Macro + Event</u>                     | <u>90</u>     |
|  | 4.366        | 0.317        | CNN_LSTM       | Macro + Event                            | 30            |
|  | 4.396        | 0.321        | CNN_GRU        | Macro + Event + Sentiment(Direct)        | 30            |
|  | 4.400        | 0.323        | CNN_LSTM       | Macro + Sentiment(Direct+Indirect)       | 60            |

### 3. 실험 결과3: 활용 목적별 환율 예측 성능 검증과 변수 중요도 분석

본 절에서는 앞서 식별된 최적 모델 조합을 활용하여 2020년부터 2024년까지의 원/달러 환율 예측 결과를 시각화하고, 예측에 기여한 주요 변수의 상대적 중요도를 정량적으로

평가하였다. 분석 결과, 제안된 LSTM 및 CNN-GRU 기반의 “Macro + Event” 및 “Macro + Event + Sentiment(Direct)” 구성은 환율의 장기 추세와 단기적 변동성을 모두 안정적으로 재현하였으며, 거시경제 변수와 금융시장 요인이 주요 기반 신호로 작용하고, 감성 및 이벤트 변수는 국면 전환기의 단기적 변동을 보완적으로 설명하는 것으로 확인되었다.

### (1) 원/달러 환율 예측 결과

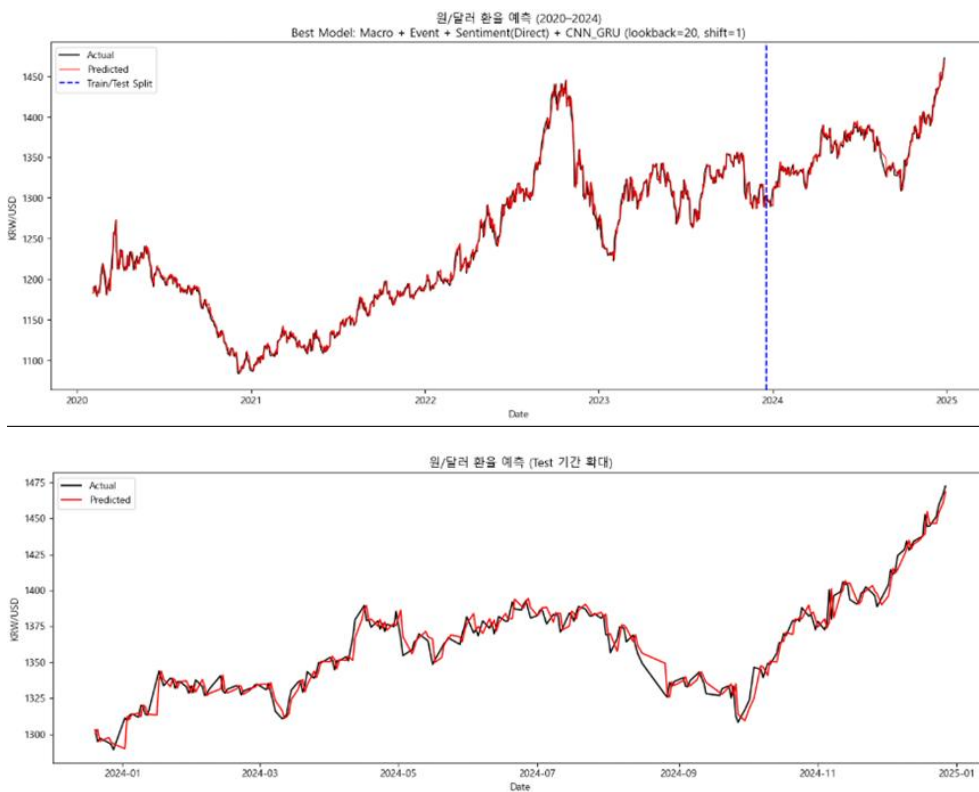
그림 [5]는 2020-2024년 기간 동안의 원/달러 환율 실제 값(Actual)과 예측 값(Predicted)을 비교한 결과를 나타낸다. 파란색 점선은 학습과 검증을 포함한 전체 구간과 테스트 구간의 경계를 나타내며, 모델의 일반화 성능을 평가하기 위해 2024년 이후의 미학습 데이터를 별도로 예측에 사용하였다. 분석 결과, 모든 모델은 코로나19 팬데믹 이후의 유동성 확장기(2020-2021), 미 연준의 긴축에 따른 환율 급등기(2022), 그리고 조정 국면(2023-2024)까지 전반적인 추세 변동을 일관되게 추적하였다. 특히 LSTM(Macro + Event, lookback=20)은 단기 충격 발생 이후의 반등 및 안정화 구간을 정확히 예측하였으며, 이는 LSTM의 순차적 게이트 구조가 사건 발생에 따른 누적 반응을 효과적으로 내재화했음을 보여준다. 특히 하단의 테스트 구간 확대 그래프에서는 실제 값과 예측 값의 단기적 차이를 상세히 비교하였다. 급격한 환율 급등락 구간에서는 일부 오차가 존재하였으나, 평균 수준과 전반적 추세 방향성은 일관되게 재현되었다.

한편, LSTM(Macro + Event + Sentiment(Direct), lookback=30) 모델은 환율 급등락 구간에서도 상대적으로 높은 적합도를 유지하였다. 테스트 구간을 확대한 세부 그래프에서는 일부 단기 변동 구간에서 예측 값이 실제 값을 약간 상회하거나 지연하는 양상이 관찰되었으나, 전체적인 방향성과 수준은 일관되게 재현되었다. 이러한 결과는 감성 변수의 추가가 단기 시장 심리를 반영하여 변동성 국면에서의 예측 안정성을 강화했음을 의미한다. 특히 뉴스의 직접적 감성(Direct Sentiment)이 시장 기대를 반영하는 고빈도 신호로 작용함으로써, 단순 거시 변수 기반 모델보다 예측 반응 속도를 향상시킨 것으로 해석된다.


결론적으로, 본 연구의 LSTM 및 CNN-GRU 기반 최적 모델들은 환율의 구조적 추세와 단기 변동성을 모두 일정 수준 포착하였으며, 이벤트와 감성 신호를 결합할 경우 단순 거시적 또는 금융 변수만을 사용할 때보다 전반적 예측력이 향상됨을 시각적으로 확인할 수 있었다.



<높은 변동성에도 일관된 환율예측 정확성: Macro + Event + LSTM (Lookback=20)>



<전반적 환율예측 정확성: Macro + Event + Sentiment(Direct) + CNN-GRU (Lookback=20)>



<비정상적 환율변동에 안정적 예측성능: Macro + Event + Sentiment(Direct) + LSTM  
(Lookback=30)>

[그림 5] 활용 목적별 최적 예측 모델 및 변수조합의 전체와 테스트 기간 시각화

## (2) 변수 중요도(Permutation Importance) 결과

모델의 예측력이 어떠한 정보에 의해 형성되는지를 파악하기 위해 Permutation Importance 분석을 수행하였다(그림 [6]). 이 방법은 각 피처(feature)의 값을 무작위로 섞은 후, 그로 인한 모델 성능 저하 정도( $\Delta$ MSE)를 계산함으로써, 개별 변수가 예측 정확도에 기여한 상대적 중요도를 추정한다. 회귀계수에 의존하지 않으며, 비선형 구조와 변수 간 상호작용을 반영할 수 있다는 점에서 딥러닝 기반 시계열 모델의 해석 가능성을 보완하는 유용한 접근법이다.

첫째, Macro + Event + LSTM (Lookback=20) 모델의 경우, S&P500과 KOSDAQ 종가가 가장 높은 중요도를 보였다. 이는 글로벌 및 국내 주식시장 흐름이 환율 변동의 선행 신호로



작용한다는 점을 실증적으로 입증한다. 다음으로 금(XAU Price)과 소비자물가지수(CPI)가 주요 변수로 도출되었으며, 실물자산과 인플레이션 요인이 환율에 구조적 영향을 미친다는 점을 보여준다. 거래량(DJI 거래량)과 주요 교환비율(USD/JPY, USD/CNY) 또한 유의미한 기여도를 보였고, 이는 주요 통화 간 상호 연동성과 글로벌 유동성이 환율 예측에 반영되고 있음을 시사한다. 한편, 이벤트 변수(gkg\_kr\_loc\_cnt)는 낮은 중요도를 보였으나, 특정 시점에서는 단기적 변동 방향을 보조적으로 설명하는 기능을 수행하는 것으로 해석된다. 전체적으로 볼 때, 거시 및 금융시장 변수군이 환율 예측의 핵심 기반을 구성하며, 이벤트 정보는 특정 국면에서 단기적 변동을 보완적으로 포착하는 신호로 기능함을 확인하였다.

둘째, Macro + Event + Sentiment(Direct) + CNN-GRU (Lookback=20) 모델에서는, 금 가격(XAU Price)이 압도적으로 높은 중요도를 보여 환율 변동의 핵심 결정 요인임을 확인하였다. 그다음으로 KOSDAQ 거래량, USD/KRW 시가, Direct News Count, Direct Sentiment Mean이 순차적으로 높은 기여도를 보였으며, 이는 실물자산과 금융시장 지표가 환율의 구조적 변동을 설명하는 주된 기반 신호로 작용함을 의미한다. 특히 뉴스량(Direct News Count)과 감성 톤(Direct Sentiment Mean)이 모두 상위권에 위치한 점은, 정보 확산과 시장 정서의 변동이 단기 환율 움직임에 실질적인 영향을 미친다는 점을 시사한다. 반면, 이벤트(GDELT) 변수군은 상대적으로 낮은 중요도를 보였으나, 국면 전환기나 충격 발생 시 단기적 방향성을 보완적으로 제공하는 것으로 해석된다. 즉, 실물자산(XAU), 금융시장(KOSDAQ, USD/KRW, CPI), 감성 신호(Direct Sentiment, News Count)가 상호 보완적으로 작용하며, 단기 변동성의 포착과 추세 예측의 균형을 동시에 달성함을 보여준다.

셋째, Macro + Event + Sentiment(Direct) + LSTM (Lookback=20) 모델의 permutation 분석에서는 뉴스 개수(Direct News Count)와 지정학적 이벤트(GDELT Location Count)가 가장 높은 중요도를 나타냈다. 이는 정보 확산과 사건 발생 빈도가 시장 심리에 직접적인 영향을 미치며, 환율 변동성을 촉발하는 단기 요인으로 작용함을 보여준다. 또한 경상수지(Current Account), 유가(WTI Price), 금 가격(XAU Price) 등 실물경제 지표 역시 주요 예측 요인으로 확인되었다. 이는 외환시장 변동이 실물경제 및 상품시장 요인과 긴밀히 연동되어 있음을 의미하며, 글로벌 유동성과 시장 변동성(VIX) 또한 단기 예측 성능에 기여하는 보조 신호로 작용했다.

셋째, Macro + Event + Sentiment(Direct) + LSTM (Lookback=20) 모델의 변수


중요도(Permutation Importance) 분석 결과, 마찬가지로 금 가격(XAU Price) 이 가장 높은 중요도를 보였으며, 이는 실물자산이 환율 변동의 구조적 기반 요인임을 명확히 보여준다. 그다음으로 뉴스 개수(Direct News Count) 와 GDELT 문서 수(gkg\_doc\_cnt) 가 높은 중요도를 기록하며, 정보 확산의 강도와 뉴스 이벤트의 빈도가 시장 심리 변동을 매개로 환율의 단기 변동성을 증폭시키는 주요 요인으로 작용함을 확인할 수 있었다. 또한 KOSPI 및 CNY 환율, 미국 10년물 금리(US10y) 등 거시와 금융 변수군이 상위권을 차지하며, 글로벌 유동성과 자산시장 흐름이 환율의 구조적 추세를 함께 설명함을 보여준다. 반면, 직접 감정 평균(Direct Sentiment Mean) 은 낮거나 미미한 중요도를 보였으며, 이는 단기 국면에서는 감성의 절대 수준보다는 정보량(News Count) 과 이벤트 발생 빈도가 시장 반응을 주도한다는 점을 시사한다.

요약하면, Permutation Importance 분석 결과, 선행연구에서 나타나는 전통적인 거시경제 및 금융시장 변수군(Macro/Market) 이 환율 예측의 기반 신호로 가장 큰 비중을 차지하였고, 이벤트(Event) 변수 는 국면 전환기의 단기적 방향성을, 감정(Sentiment) 변수는 시장 심리 변화를 반영하여 모델의 예측 민감도를 높이는 보조적 역할을 수행하였다. 이는 환율 예측에서 거시적 요인과 사건 정보가 구조적 변동을 설명하는 1차 요인으로, 감정 신호는 단기 변동성을 조정하는 미시적 조정 요인으로 작동하며 시너지를 명확히 보여준다.


요약하면, Permutation Importance 분석 결과, 환율 예측의 주된 기반 신호는 여전히 거시경제 및 금융시장 변수(Macro/Market)에 의해 형성되며, 실물자산 가격(특히 금 XAU Price)이 전 구간에서 가장 높은 중요도를 차지하였다. 이는 실물자산이 환율 변동의 구조적 동인으로 작용함을 실증적으로 보여준다. 다음으로, 정보 확산 관련 변수(Direct News Count, GDELT 문서 수) 가 높은 중요도를 보이며, 뉴스량과 사건 빈도가 시장의 단기 심리 변동을 매개로 환율의 단기적 움직임을 촉발하는 핵심 요인으로 확인되었다. 이는 환율이 단순한 거시 지표의 함수가 아니라, 정보의 양적 흐름과 뉴스 네트워크의 밀도에 의해 비선형적으로 반응하는 복합적 시스템임을 시사한다. 반면, 직접 감정 평균(Direct Sentiment Mean) 은 상대적으로 낮은 중요도를 보여, 단기 국면에서는 감성의 절대 수준보다 정보 확산의 강도와 이벤트의 빈도가 시장 반응을 주도함을 의미한다. 그러나 감정 변수는 중기 예측 구간에서 모델의 예측 안정성과 민감도 균형을 보완적으로 향상시키는 역할을 수행하였다. 또한, KOSDAQ 거래량, USD/KRW 시가, 주요 교환비율(USD/CNY, USD/JPY) 등 금융시장 변수군과 미국 10년물 금리(US10y), CPI,

유가(WTI) 등 거시 지표 역시 상위권에 위치하며, 글로벌 유동성과 자산시장 흐름이 환율 예측의 구조적 기반을 함께 형성함을 보여준다.


종합적으로, 본 연구의 결과는 거시경제 및 금융시장 변수가 환율의 구조적 추세를, 이벤트 변수가 단기적 방향성과 충격 반응을, 감성 변수가 시장 정서의 미시적 조정 효과를 담당하며, 세 신호군이 시간 창구별 상보적 역할 구조를 형성함을 실증적으로 규명하였다. 즉, 거시-이벤트-감성의 다층 신호 융합 구조가 환율 변동성을 설명하는 핵심 메커니즘임을 보여준다.



<높은 변동성에도 일관된 환율예측 정확성: Macro + Event + LSTM (Lookback=20)>



<전반적 확률예측 정확성: Macro + Event + Sentiment(Direct) + CNN-GRU  
(Lookback=20)>



<비정상적 환율변동에 안정적 예측성능: Macro + Event + Sentiment(Direct) + LSTM  
(Lookback=30)>

[그림 6] 활용 목적별 최적 예측 모델 및 변수조합에서의 변수 중요도 분석 결과

## V. 토의 및 시사점

본 연구는 환율 예측에서 예측 목적에 따라 지배 신호가 감성 → 감성 및 이벤트 복합 → 사건 중심으로 이동한다는 동태적 전이를 실증하였다. 모델 차원에서도 단/중기에는 합성곱-순환 하이브리드(CNN-GRU/-LSTM)가, 장기에는 순수 LSTM 이 구조적 우위를 보였다. Permutation Importance 결과는 주식, 원자재, 물가, 금리 등 거시 및 시장 변수가 기반 신호로, 이벤트 및 감성 변수가 국면 전환기의 단기 변동을 증폭 또는 완충하는 보조 신호로 기능함을 확인하였다. 이러한 결과는 금융정책 운영에서 목적맞춤형 모델 포트폴리오와 시간대별 신호 체계를 결합한 데이터 기반 의사결정이 필요함을 시사한다.

단기(5-10일) 구간에서 이벤트와 감성 신호가 예측력을 유의하게 높였다는 사실은, 시장 심리의 급변이 환율의 고빈도 변동을 주도함을 의미한다. 통화와 환율정책 차원에서는 다음과 같은 연계가 요구된다. 첫째, 고빈도 심리 및 사건 지표(Direct News Count, Sentiment Tone, GDELT Event Density)를 활용한 경보 시스템을 마련한다. 설정된 임계치를 상회할 때 시장점검회의 자동 소집, 선물환과 스왑 유동성 공급 등 미시적 안정 장치를 단계적으로 가동한다. 둘째, 정책 타이밍과 커뮤니케이션을 감성지수와 정합화한다. 과도한 긴축/완화 정책이 군집행동을 자극하지 않도록 메시지의 톤과 빈도를 데이터로 관리한다. 셋째, 중기(20-30일)적 이벤트와 감성지수를 통합하여 정책 내부의 지표로써 채택한다. 본 연구에서 20일 창구의 CNN-GRU(Macro+Event+Direct Sentiment)와 30일 창구의 LSTM(Macro+Event)가 각각 평균오차와 추세 안정성에서 우수했으므로, 정책경로 점검과 대외적 대응시 두 창구의 시그널을 병행 참조하는 체계를 권고할 수 있다.

단기 안정은 감성과 이벤트 기반의 고빈도 감시와 경보 시스템, 중기 조기경보는 20-30일 복합 신호의 체계적 지표 활용, 장기 정책판단은 거시와 시장 누적 신호에 근거해야 한다. 과적합을 피한 “Macro+Event( $\pm$ Direct Sentiment)”의 간결 변수 구성과 목적맞춤형 모델 포트폴리오는 외환정책의 예측 가능성과 효율성을 동시에 제고할 것이다.

## VI. 결론

본 연구는 2020년부터 2024년까지의 원/달러 환율 데이터를 대상으로, 1일 선행 예측 문제를 중심으로 LSTM, GRU, CNN-LSTM, CNN-GRU 네 가지 딥러닝 아키텍처와 Macro, Event, Sentiment, Event+Sentiment의 네 가지 입력 구성을 동일한 실험 설계 하에 비교 및 분석하였다. 데이터의 시계열적 누수(leakage)를 철저히 차단하고, RobustScaler 정규화와 다중 시드(Seed) 반복 학습을 통해 초기화 민감도를 완화함으로써 실험의 재현성과 공정성을 확보하였다.

그 결과, 시간 창구가 길어질수록 환율을 지배하는 정보 신호의 구조가 감성 중심에서 감성 및 이벤트 복합 중심으로, 그리고 거시/정책/글로벌 사건 중심으로 동태적으로 전이됨이 확인되었다. 즉, 단기(5-10일)에는 뉴스 감성(Direct Sentiment)과 같은 고빈도 정서 신호가 시장 변동을 주도하고, 중기(20-30일)에는 감성과 이벤트가 상호작용하여 비선형적 예측력을 강화하며, 장기(60-90일)에는 거시/시장/정책 변수의 누적 효과가 환율 추세의 주요 결정 요인으로 전환되었다. 이는 환율의 단기 변동이 정서적 반응에 의해, 장기 변동은 구조적 충격의 누적으로 설명된다는 기존 경제 및 금융 이론과 일관된 결과이다.

모델 구조의 최적 성능 또한 시간 창구에 따라 달라졌다. 단기에서는 합성곱 계층이 국소적 급등락 패턴을 포착하고 순환 계층이 이를 흡수하는 CNN-하이브리드 구조(특히 CNN-GRU, CNN-LSTM)가 우세했으며, 중기 이후에는 순수 LSTM 구조가 가장 넓은 Radar 면적과 낮은 오차를 보였다. 특히 lookback 30~90일 구간에서는 LSTM의 장기 메모리 셀이 사건의 누적적 상관관계를 안정적으로 학습하여 Conv1D 기반 모델보다 구조적으로 효율적이었다. 이러한 결과는 시점 간 의존성 보존이 장기 환율 예측의 핵심임을 실증적으로 보여준다.

예측 목적별 분석에서도 일관된 패턴이 관찰되었다. 고변동 환경에서의 일관성(RMSE · MSPE)은 LSTM(Macro + Event) 조합이 가장 우수하였다. 평균적 예측 정확도(MAE · MAPE)는 CNN-GRU(Macro + Event + Sentiment(Direct))가 최적이었다. 비정상적 변동의 강건성(MedAE · MedAPE)은 LSTM(Macro + Event + Sentiment(Direct))이 가장 안정적이었다. 이러한 결과는 환율 예측의 세 가지 목적(정확성, 안정성, 강건성)에 따라 모델 및 변수 조합의 최적 구조가 다르게 설정되어야 함을 시사한다. 특히 Macro와 Event는 모든 구간에서 예측의 공통 기반(Core Foundation)으로 작용하였으며, Direct Sentiment는 중기 예측에서 평균 오차 축소 및 꼬리 위험 억제에 실질적으로 기여하였다. 반면, 모든

변수를 과도하게 결합할 경우 정보 중복과 다중공선성(Multicollinearity)에 의해 오히려 일반화 성능이 저하되는 경향이 확인되었다.

Permutation Importance 분석은 이러한 구조적 전이를 계량적으로 뒷받침한다. Macro+Event+LSTM(Lookback=20)에서는 S&P500, KOSDAQ, 금(XAU), CPI 가 최상위 요인으로, Macro+Event+Sentiment(Direct)+LSTM(Lookback=30)에서는 실물자산(금, 알루미늄) 과 국내외 주식시장 지표가 핵심 변수로 나타났다. 반면 lookback 20의 감성 및 이벤트 결합형 모델에서는 뉴스량(Direct News Count) 과 GDELT 위치 빈도가 높은 중요도를 보였다. 즉, 정보 확산과 사건 발생 빈도는 단기 변동성을, 실물 및 금융 지표는 장기 구조적 변동성을 설명하는 상호보완적 역할을 수행함이 입증되었다.

Permutation Importance 분석 결과는 이러한 시간 창구별 구조적 전이를 계량적으로 입증하였다. 먼저, Macro + Event + LSTM (Lookback=20) 모델에서는 S&P500, KOSDAQ, 금(XAU), CPI가 가장 높은 중요도를 보이며, 글로벌 및 국내 주식시장 흐름과 실물자산, 그리고 인플레이션 요인이 환율의 구조적 변동을 주도함을 확인하였다. 반면, Macro + Event + Sentiment(Direct) + CNN-GRU (Lookback=20) 모델에서는 금(XAU Price) 이 여전히 핵심 변수로 유지되었으나, 그다음으로 KOSDAQ 거래량, USD/KRW 시가, Direct News Count, Direct Sentiment Mean 등이 높은 기여도를 보였다. 이는 실물자산과 금융시장 지표가 환율의 장기적 구조를 형성하는 한편, 정보 확산과 감성 신호가 단기적 시장 반응을 강화하는 보완적 역할을 수행함을 보여준다. 또한, Macro + Event + Sentiment(Direct) + LSTM (Lookback=30) 모델에서는 마찬가지로 금이 가장 큰 핵심 변수였으며, Direct News Count와 GDELT 문서 수(gkg\_doc\_cnt) 가 다음 상위권에 위치하며, 뉴스 및 사건 발생 빈도가 단기 변동성의 주요 축매로 작용함을 입증하였다. 이와 대조적으로 Direct Sentiment Mean은 상대적으로 낮은 중요도를 보여, 감성의 절대 수준보다는 정보량과 이벤트 밀도가 시장 반응을 결정짓는 주요 신호임이 드러났다. 요컨대, 정보 확산(뉴스량 및 GDELT) 은 단기 변동성을, 실물자산 및 금융지표(금, 주가지수, 금리) 는 구조적 추세 변동을 설명하며, 감성 신호는 중기 구간에서 두 신호 간 민감도를 조정하는 완충적 요인으로 기능한다. 따라서 환율 예측의 핵심은 단일 변수군이 아닌, 거시-이벤트-감성 간 상호보완적 신호 융합 구조에 기반함을 실증적으로 확인하였다.

이러한 발견은 학술적으로 시계열-비정형 융합모델의 구조적 정합성을 실증적으로

제시했다는 점에서 의의가 크다. 본 연구는 동일한 데이터, 전처리, 평가 체계하에서, 시간 창구, 모델 구조, 입력 신호 간의 상호작용 효과를 계량적으로 검증하고, Radar chart 및 중요도 분석을 통해 그 전이 과정을 시각화하였다. 특히 구조적 전이 패턴이 시간 축을 따라 연속적으로 발생한다는 점을 정량적으로 확인함으로써, 기존 단일 프레임 기반의 환율 예측 연구를 한 단계 확장하였다.

정책적 관점에서도 본 연구는 실질적 함의를 갖는다. 변동성 관리, 평균 정확도, 강건성이라는 세 가지 목표에 따라 예측 창구별 맞춤형 모델 포트폴리오를 설계해야 하며, Macro+Event를 공통 코어로 유지하면서 중기 구간에서는 Direct Sentiment를 선택적으로 결합하는 것이 가장 합리적이다. 단기 고빈도 대응에는 CNN-하이브리드가, 장기 추세 예측과 자금운용 및 헷지 전략에는 순수 LSTM 기반 모델이 적합하다. 이는 금융정책 및 외환시장 운영에서 시간 창구별 맞춤형 AI 예측 체계가 필요함을 시사한다.

다만 본 연구는 1일 고정 선행 예측과 단일 통화쌍(KRW/USD)에 한정되며, 감성 및 이벤트 데이터의 표본화와 정책 변수의 내생적 반응을 명시적으로 통제하지 못한 한계가 있다. 향후 연구에서는 다중 시점 예측(Multi-horizon Forecasting), 정책 및 지정학 이벤트의 세분 인코딩, 대규모 언어모델(LLM)을 활용한 고급 감성 추출, 정책 불확실성 및 금융 스트레스 지수의 통합, Transformer 기반 멀티모달 시계열 모델 등을 통해 확장할 필요가 있다.


결론적으로, 본 연구는 환율 예측의 본질이 시간 창구별 지배 신호의 구조적 전이에 있으며, 이에 부합하는 모델 구조와 입력 구성이 예측 성능과 해석 가능성을 결정한다는 점을 실증적으로 규명하였다. Macro와 Event는 전 구간의 기반, Direct Sentiment는 중기적 비선형 반응을 보완하는 핵심 보조 신호, 그리고 동태적 전이를 고려한 설계가, 고변동 환경에서도 안정적이고 설명 가능한 환율 예측을 가능하게 하는 최적의 접근임을 명확히 보여준다.



## 부록

### A. 변수 상관관계 히트맵

[그림 7]는 변수 간 상관관계 히트맵을 제시한 것이다. 결과를 보면 환율과 주가, 금리, 원자재 가격 등 주요 거시·시장 지표들은 서로 강한 양(+)의 상관 혹은 음(-)의 상관을 보이며, 전형적인 금융 변수들 간 공분산 구조가 나타난다. 뉴스 감성 지표들 역시 서로 밀접한 상관관계를 형성하고 있음을 확인할 수 있다.



[그림 7] 변수 상관관계 히트맵

## References

- Agustin, F., & De Melin, P. (2024). Comparison of GRU and CNN Methods for Predicting the Exchange Rate of Argentine Peso (ARS) against US Dollar (USD). *International Journal Artificial Intelligent and Informatics*, 2(1), 9-16.
- Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*.
- Barbella, M., & Tortora, G. (2022). Rouge metric evaluation for text summarization techniques. *Available at SSRN 4120317*.
- Blanqué, P., Ben Slimane, M., Cherief, A., Le Guenedal, T., Sekine, T., & Stagnol, L. (2022). Monitoring Narratives: An Application to the Equity Market. *Available at SSRN 4078945*.
- Cambria, E., Poria, S., Gelbukh, A., & Thelwall, M. (2018). Sentiment analysis is a big suitcase. *IEEE Intelligent Systems*, 32(6), 74-80.
- Cao, W., Zhu, W., Wang, W., Demazeau, Y., & Zhang, C. (2020). A deep coupled LSTM approach for USD/CNY exchange rate forecasting. *IEEE Intelligent Systems*, 35(2), 43-53.
- Consoli, S., Tiozzo Pezzoli, L., & Tosetti, E. (2020). Information extraction from the GDELT database to analyse EU sovereign bond markets. *Workshop on Mining Data for Financial Applications*.
- Dalal, A., Ranjan, S., Bopaiah, Y., Chembachere, D., Steiger, N., Burns, C., & Daswani, V. (2024). Text summarization for pharmaceutical sciences using hierarchical clustering with a weighted evaluation methodology. *Scientific Reports*, 14(1), 20149.
- Ding, H., Shi, X., Deng, R., Faroog, S., Dewi, D. A., Abdullah, S. N., & Malek, B. A. (2024). EUR/USD exchange rate forecasting incorporating text mining based on pre-trained language models and deep learning methods. *arXiv preprint arXiv:2411.07560*.
- Gupta, S., Ranjan, R., & Singh, S. N. (2024). Comprehensive study on sentiment analysis: From rule-based to modern LLM-based systems. *arXiv preprint arXiv:2409.09989*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*,

9(8), 1735-1780.

Islam, M. S., & Hossain, E. (2021). Foreign exchange currency rate prediction using a GRU-LSTM hybrid network. *Soft Computing Letters*, 3, 100009.

Jing, N., Wu, Z., & Wang, H. (2021). A hybrid model integrating deep learning with investor sentiment analysis for stock price prediction. *Expert Systems with Applications*, 178, 115019.

Kang, J.-W., & Choi, S.-Y. (2025). Comparative investigation of GPT and FinBERT' s sentiment analysis performance in news across different sectors. *Electronics*, 14(6), 1090.

Lu, W., Li, J., Li, Y., Sun, A., & Wang, J. (2020). A CNN-LSTM-based model to forecast stock prices. *Complexity*, 2020(1), 6622927.

Mohan, S., Mullapudi, S., Sammeta, S., Vijayvergia, P., & Anastasiu, D. C. (2019). Stock price prediction using news sentiment analysis. *2019 IEEE Fifth International Conference on Big Data Computing Service and Applications (BigDataService)*.

Nasiopoulos, D. K., Roumeliotis, K. I., Sakas, D. P., Toudas, K., & Reklitis, P. (2025). Financial sentiment analysis and classification: A comparative study of fine-tuned deep learning models. *International Journal of Financial Studies*, 13(2), 75.

Plakandaras, V., Papadimitriou, T., & Gogas, P. (2015). Forecasting daily and monthly exchange rates with machine learning techniques. *Journal of Forecasting*, 34(7), 560-573.

Qu, Y., & Zhao, X. (2019). Application of LSTM neural network in forecasting foreign exchange price. *Journal of Physics: Conference Series*.

Qureshi, A. M. (2025). *ML Forecasting of Exchange Rates: Machine Learning Prediction of Exchange Rates Using Macroeconomic Indicators*. Available at SSRN 5287273.

Schroeder, C., Winterbottom, S., Sitter, R., & Perdigones, J. L. (2013). Big Data Analysis of Human Societal Events: Indications for Forecasting Currency Exchange Rates.

Shen, Y., & Zhang, P. K. (2024). Financial sentiment analysis on news and reports using large language models and FinBERT. *2024 IEEE 6th International Conference on Power, Intelligent Computing and Systems (ICPICS)*.

Wang, J., Wang, X., Li, J., & Wang, H. (2021). A prediction model of CNN-TLSTM for USD/CNY exchange rate prediction. *IEEE Access*, 9, 73346-73354.

Zhang, M., Li, C., Wan, M., Zhang, X., & Zhao, Q. (2024). ROUGE-SEM: Better evaluation of summarization using ROUGE combined with semantics. *Expert Systems with Applications*, 237, 121364.

Zheng, W., & Chen, G. (2021). An accurate GRU-based power time-series prediction approach with selective state updating and stochastic optimization. *IEEE Transactions on Cybernetics*, 52(12), 13902-13914.

김인준, & 이영섭. (2019). *국제경제론*. 박영사.

김우석, & 한규식. (2021). COVID-19가 원달러환율에 미친 영향. *금융지식연구*, 19(1), 33-58.

임현욱, 정승환, 이희수, & 오경주. (2021). 국고채, 금리 스왑 그리고 통화 스왑 가격에 기반한 외환시장 환율예측 연구: 인공지능 활용의 실증적 증거. *지식경영연구*, 22(4), 71-85.

오인정, & 김우주. (2022). SARIMA와 ARDL 모형을 활용한 COVID-19 구간별 원/달러 환율 예측. *지능정보연구*, 28(4), 191-209.

정가연, 이혁제, 이준영, & 이제혁. (2024). 금융 특화 감정분석 모델과 딥러닝 시계열 예측 모델을 활용한 코스피 지수 예측. *대한산업공학회지*, 50(4), 240-250.

# Reading Global Issues with AI

## : Event and Sentiment Fusion for Exchange Rate Prediction in Korea

Jaheung Park<sup>1</sup>, Kyungwon Kim<sup>2</sup>

### Abstract

This study proposes a deep learning-based forecasting model for the USD/KRW exchange rate that integrates macroeconomic and financial indicators with news-based event data (GDELT) and sentiment summaries. Four architectures—LSTM, GRU, CNN-LSTM, and CNN-GRU—were compared across multiple input combinations and time windows (lookback = 5–90 days), revealing dynamic structural shifts in predictive dominance depending on temporal scope. In short horizons, sentiment-driven CNN hybrids performed best; in mid-term windows, event-sentiment fusion models such as CNN-GRU achieved superior nonlinear responsiveness; and in long-term horizons, event-focused LSTM models provided the most stable forecasts. Permutation importance analysis identified commodity prices (gold, oil, aluminum), U.S. policy and bond rates, stock indices, and sentiment volatility as key explanatory factors. Visualization results confirmed that the proposed models effectively captured both the overall trend and short-term fluctuations of the exchange rate. These findings demonstrate that integrating event and sentiment information enhances the accuracy and interpretability of exchange rate forecasting, underscoring the value of combining time-series and textual signals in financial prediction.

**Keywords:** Exchange Rate, Time Series Forecasting, Deep Learning, Global Events, News Sentiment

---

<sup>1</sup> Department of International Trade, Incheon National University, Incheon, Republic of Korea;  
Email: james2p@inu.ac.kr

<sup>2</sup> Department of International Trade, Incheon National University, Incheon, Republic of Korea;  
Email: thekimk.kr@gmail.com